Universidad de Sevilla

Escuela Técnica Superior de Ingeniería Informática

Departamento de Ciencias de la Computación e Inteligencia Artificial



Máster Universitario en Lógica, Computación e Inteligencia Artificial

Trabajo de Fin de Máster

Métodos topológicos en segmentación de imágenes

Dirigido por:
Manuel Soriano Trigueros

Realizado por:
Agustín Galiana Carballido

Presentado el 6 de noviembre de 2026

Índice general

Resumen **1**

English Abstract **3**

1. Introducción **5**

1.1. Motivación 5

1.2. Objetivos 6

1.3. Contribuciones 6

1.4. Estructura de la memoria 7

2. Fundamentos de topología computacional **9**

2.1. Complejos 10

2.1.1. Complejos simpliciales 10

2.1.2. Complejos cúbicos 11

2.1.3. Imágenes como complejos filtrados 12

2.2. Homología 14

2.2.1. Cadenas, ciclos y bordes 14

2.2.2. Grupos de homología y números de Betti 15

2.2.3. Inclusiones inducidas 17
2.2.4. Cálculo mediante reducción matricial 18
2.3. Homología persistente 19
2.3.1. Filtraciones 20
2.3.2. Grupos persistentes y diagramas 22
2.3.3. Algoritmo de reducción 23
2.3.4. Árboles de fusión y *union-find* en dimensión 0 24
2.4. Distancias entre diagramas y estabilidad 25
2.5. Dice y clDice 26
2.5.1. Coeficiente de Dice 26
2.5.2. Esqueleto y clDice 27
2.6. Topología en la segmentación de imágenes 28
2.6.1. Topograph 29
2.6.2. Comparación 32

3. Contexto del problema **33**
3.1. Filamentos solares 33
3.2. El conjunto de datos MAGFiLO 34
3.3. La competición *Solar Filament Segmentation Challenge 2026* 36
3.4. Trabajos previos en detección automática de filamentos 39
3.5. Dificultades del problema 40

4. Planteamiento **41**
4.1. Diagnóstico de la baseline 41
4.1.1. Taxonomía de errores 41

4.1.2. Recuperabilidad 42
4.1.3. Dónde falla el modelo 43
4.1.4. El techo humano 44
4.2. Lectura topológica del post-proceso 44
4.2.1. Instancias y diagrama de persistencia 44
4.2.2. La firma de cada error 45
4.2.3. Área frente a persistencia 46
4.3. Hipótesis y estrategia 47
4.4. Cómo medir una mejora 49

5. Metodología **51**
5.1. Datos y partición 51
5.2. Modelo y entrenamiento 52
5.3. Pérdidas 53
5.4. Post-proceso 54
5.5. Ajuste de hiperparámetros 56
5.6. Evaluación 56
5.6.1. Tipos de error 57
5.6.2. Barbas 58
5.6.3. Incertidumbre 59
5.7. Reproducibilidad 59

6. Experimentos y resultados **61**
6.1. Punto de partida 61
6.2. La topología en el entrenamiento 62

6.2.1. Predicciones más fiables 63
6.2.2. Topograph y el filtro de área 65
6.3. La topología en el post-proceso 67
6.4. Experimentos adicionales 68
6.4.1. Barbas 68
6.4.2. Ajuste de hiperparámetros 69
6.4.3. Test de la competición 69

7. Conclusiones y trabajo futuro **71**
7.1. Conclusiones 71
7.2. Limitaciones 73
7.3. Trabajo futuro 73

A. Código y reproducibilidad **75**
A.1. Organización 75
A.2. Reproducir un resultado 75
A.3. Post-proceso por persistencia 77

B. Resultados complementarios **79**
B.1. Post-proceso de umbral y área 79
B.2. Comparación de pérdidas 80
B.3. Incertidumbre de las comparaciones 82
B.4. Post-proceso por persistencia 83
B.5. Barbas 84
B.6. Ajuste de hiperparámetros 87

B.7. Test de la competición 89

Resumen

Este trabajo estudia la topología computacional y su uso en la segmentación de imágenes. Se exponen los fundamentos de la homología persistente: complejos simpliciales y cúbicos, grupos de homología y números de Betti, filtraciones y diagramas de persistencia, su cálculo por reducción matricial o, en dimensión 0, por *union-find*, y su estabilidad frente a perturbaciones. Después se presentan los métodos que llevan la topología a la segmentación, en particular Topograph, una pérdida que penaliza solo las regiones que cambian la topología de la predicción.

Estos conocimientos se aplican a la segmentación de filamentos solares en imágenes H-alfa, un problema en el que los errores que más pesan son topológicos: filamentos partidos, fusionados o manchas espurias. La red asigna a cada píxel una probabilidad de ser filamento, y el post-proceso habitual conserva los píxeles que superan un umbral y descarta las componentes pequeñas. Al bajar el umbral, cada componente nace en el valor de su máximo y muere al unirse con otra más alta, y ese par de valores es un punto del diagrama de persistencia H_0. Se demuestra que las instancias que deja un umbral son los puntos nacidos por encima de él y aún vivos, así que fijar el umbral es elegir qué puntos del diagrama pasan a ser instancias. Cada error se reconoce además en el diagrama. Un filamento partido da varios puntos, dos fusionados dejan uno solo y una mancha espuria es un punto sin filamento debajo. Esta lectura guía dos formas de corregir esos errores: durante el entrenamiento, con pérdidas topológicas como clDice y Topograph, y después, con un post-proceso que decide qué componentes conservar según su persistencia.

Topograph hace predicciones más fiables, con mayor precisión y muchas menos predicciones espurias, aunque en la métrica se obtienen resultados similares simplemente filtrando los segmentos por área. El post-proceso por persistencia conserva la estructura y reduce la fragmentación, y, combinado con el filtro de área sobre un modelo entrenado con Topograph, da los menores errores de estructura. No separa, en cambio, las predicciones espurias muy seguras, porque ahí la persistencia apenas se distingue de la confianza del modelo. En conjunto, la topología permite entender y clasificar con precisión los errores de segmentación y da criterios para corregirlos que el tamaño no ofrece.

English Abstract

This work studies computational topology and its use in image segmentation. It presents the foundations of persistent homology: simplicial and cubical complexes, homology groups and Betti numbers, filtrations and persistence diagrams, their computation by matrix reduction or, in dimension 0, by union-find, and their stability under perturbations. It then presents the methods that bring topology into segmentation, in particular Topograph, a loss that penalises only the regions that change the topology of the prediction.

This knowledge is applied to the segmentation of solar filaments in H-alpha images, a problem in which the most costly errors are topological: split or merged filaments and spurious blobs. The network assigns each pixel a probability of being a filament, and the usual post-processing keeps the pixels above a threshold and discards small components. As the threshold is lowered, each component is born at the value of its maximum and dies when it merges with a higher one, and that pair of values is a point of the H_0 persistence diagram. We prove that the instances left by a threshold are the points born above it and still alive, so fixing the threshold amounts to choosing which points of the diagram become instances. Each error can also be recognised in the diagram. A split filament gives several points, two merged filaments leave only one, and a spurious blob is a point with no filament underneath. This reading guides two ways of correcting those errors: during training, with topological losses such as clDice and Topograph, and afterwards, with a post-processing that decides which components to keep according to their persistence.

Topograph produces more reliable predictions, with higher precision and far fewer spurious predictions, although similar results in the metric are obtained simply by filtering the segments by area. Persistence-based post-processing preserves structure and reduces fragmentation, and, combined with the area filter on a model trained with Topograph, it yields the fewest structural errors. It does not, however, separate highly confident spurious predictions, because there persistence barely differs from the model's confidence. Overall, topology makes it possible to understand and classify segmentation errors precisely, and gives criteria to correct them that size alone does not.

1 Introducción

1.1 Motivación

Las redes neuronales de segmentación se entrenan casi siempre con pérdidas de solapamiento, como la entropía cruzada o el coeficiente de Dice, que comparan la predicción con la referencia píxel a píxel. Esto funciona bien en la mayoría de los casos. Pero cuando lo que se segmenta son estructuras finas y alargadas (vasos sanguíneos, carreteras, fibras), los errores que más importan no son los que más píxeles cuestan. Un vaso partido en dos por un hueco de tres píxeles apenas cambia el Dice y, sin embargo, ha dejado de ser un vaso para convertirse en dos. Son errores que cambian cuántas piezas hay y cómo se conectan.

La topología es la parte de las matemáticas que estudia precisamente esas propiedades, las que no cambian al deformar un objeto sin romperlo ni pegarlo. En los últimos años, la topología computacional, y en particular la homología persistente, ha dado lugar a métricas y pérdidas que penalizan directamente los errores topológicos de una segmentación [16, 24, 27, 21]. Este trabajo estudia esas herramientas y las pone a prueba en un problema real.

El problema elegido es la segmentación de filamentos solares en imágenes H-alfa, propuesto en la competición *Solar Filament Segmentation Challenge 2026* [2]. Los filamentos son estructuras alargadas, con ramificaciones finas llamadas *barbas*, y la competición los evalúa con una métrica de instancias, la calidad panóptica [19], que castiga con fuerza los filamentos partidos o fusionados. Es, por tanto, un caso en el que los errores topológicos tienen un coste directo y medible.

Enfoque. El trabajo no parte de aplicar una pérdida topológica y medir si mejora la métrica, sino de entender primero qué errores comete un modelo de referencia. Ese

diagnóstico conduce a una observación sencilla: el post-proceso habitual, que umbraliza la probabilidad y toma componentes conexas, tiene una lectura exacta en términos de homología persistente. Las instancias que produce son puntos de un diagrama de persistencia, y cada tipo de error deja en él una firma reconocible. Esta lectura permite actuar sobre los errores topológicos en dos momentos: durante el entrenamiento, con pérdidas como clDice y Topograph, y después de él, con un post-proceso que decide qué componentes conservar según su persistencia. El trabajo estudia ambas vías bajo un mismo protocolo, y cómo interactúan entre sí.

1.2 Objetivos

El objetivo general es estudiar qué aporta la topología computacional a la segmentación de estructuras finas, tanto en la teoría como en la práctica. Se concreta en cuatro objetivos:

O1. Estudiar los fundamentos de la homología y la homología persistente, y los métodos de segmentación que se basan en ellas, en particular Topograph [21].
O2. Construir un protocolo de experimentación reproducible para la segmentación de filamentos, en el que las comparaciones entre métodos no dependan de decisiones tomadas sobre los datos de evaluación.
O3. Diagnosticar los errores de un modelo de referencia, interpretarlos en términos topológicos y usar esa lectura para diseñar un post-proceso basado en persistencia.
O4. Evaluar si las pérdidas con sesgo topológico (clDice y Topograph) mejoran a las pérdidas de solapamiento, en la métrica de la competición, en los tipos de error y en la detección de las barbas, y cómo interactúan con el post-proceso.

1.3 Contribuciones

- Una exposición de la homología persistente y de Topograph centrada en la intuición y con ejemplos, pensada para un lector con formación matemática pero sin experiencia previa en topología computacional.
- Una lectura topológica del post-proceso habitual: el número de instancias predichas a un umbral es el número de puntos de un cuadrante del diagrama de

persistencia H_0, y cada tipo de error (fragmentación, fusión, filamento perdido o predicción espuria) deja en él una firma reconocible.
- Un post-proceso basado en persistencia derivado de esa lectura, en dos variantes: E2, que filtra las componentes por persistencia y une las que separa un collado cercano al umbral, y B2+P, que combina el criterio de persistencia con el de área.
- Una comparación controlada de diez pérdidas, combinando BCE con Dice, IoU y clDice, con y sin Topograph, bajo un mismo protocolo, con separación entre ajuste y reporte, intervalos de confianza y un recuento de los tipos de error que distingue los errores de estructura de los de presencia.
- Los resultados principales. Topograph hace predicciones más fiables: sin post-proceso, todas sus variantes tienen mayor precisión y entre un 38 y un 63 % menos de predicciones sin filamento, y es la pérdida con mejor PQ. El filtro de área corrige ese mismo tipo de error, y con él las diferencias de PQ quedan dentro del ruido. El post-proceso por persistencia conserva la estructura, sin perder apenas filamentos y reduciendo la fragmentación, pero no separa las predicciones espurias muy seguras. Combinado con el área y con Topograph, da menos errores de estructura que el filtro de área solo.
- Una medida de la detección de las barbas basada en la espina anotada en MAGFiLO, con la que se comprueba que ninguna pérdida topológica mejora su detección.
- El código, público, con el que se puede reproducir cada resultado.

1.4 Estructura de la memoria

El Capítulo 2 presenta los fundamentos de topología computacional y los métodos topológicos de segmentación. El Capítulo 3 describe el problema: los filamentos solares, el conjunto de datos MAGFiLO, la competición y los trabajos previos. El Capítulo 4 diagnostica los errores de un modelo de referencia, desarrolla la lectura topológica del post-proceso y plantea las hipótesis y las líneas de mejora. El Capítulo 5 detalla el protocolo experimental, y el Capítulo 6, los resultados. El Capítulo 7 recoge las conclusiones, las limitaciones y el trabajo futuro. Por último, el Apéndice A describe el código y cómo reproducir cada experimento, y el Apéndice B recoge las tablas completas de resultados.

2 Fundamentos de topología computacional

El análisis topológico de datos (TDA, por sus siglas en inglés) estudia la *forma* de los datos: cuántas componentes tienen, si presentan agujeros o cavidades y cómo se conectan entre sí. Una de sus herramientas más importantes es la homología persistente, que estudia cómo evolucionan las componentes y los agujeros de una familia creciente de espacios y permite así distinguir la estructura robusta del ruido. Este capítulo, núcleo teórico del trabajo, presenta estas herramientas siguiendo principalmente a Edelsbrunner y Harer [11]: los complejos (Sección 2.1), la homología (Sección 2.2) y la homología persistente (Sección 2.3). Después introducimos las distancias entre diagramas de persistencia, que permiten compararlos de forma estable (Sección 2.4).

La segunda parte del capítulo se centra en las técnicas de segmentación de imágenes basadas en TDA, donde la forma importa tanto como la precisión: un objeto partido en dos o unido a otro por un puente espurio apenas penaliza una métrica de solapamiento, pero cambia su topología. Presentamos primero el coeficiente de Dice y clDice (Sección 2.5), que miden el solapamiento de los píxeles y de los esqueletos, respectivamente. Después describimos las métricas y funciones de pérdida basadas en topología (Sección 2.6), con especial atención a *Topograph* [21].

Trabajamos siempre con coeficientes en el cuerpo $\mathbb{F}_2 = \{0, 1\}$, donde $1 + 1 = 0$. Esta elección simplifica los cálculos (no hay signos ni orientaciones) y es la habitual en topología computacional.

2.1 Complejos

Para calcular invariantes topológicos con un ordenador necesitamos representar los espacios de forma finita y combinatoria. Los complejos simpliciales son la representación clásica; los complejos cúbicos son la adaptada a imágenes.

2.1.1 Complejos simpliciales

Sean $u_0, \dots, u_p \in \mathbb{R}^d$ puntos afínmente independientes, es decir, tales que los vectores $u_i - u_0$, $1 \leq i \leq p$, son linealmente independientes.

Definición 2.1 ([11, §III.1]). *Un* p-símplice *es la envolvente convexa de* $p+1$ *puntos afínmente independientes* $u_0, \dots, u_p$*, que se denota* $\sigma = \operatorname{conv}\{u_0, \dots, u_p\}$*; su* dimensión *es* $\dim \sigma = p$*. Una* cara *de* σ *es la envolvente convexa de un subconjunto no vacío de los* u_i*; escribimos* $\tau \leq \sigma$*.*

Los símplices de dimensión 0, 1, 2 y 3 son vértices, aristas, triángulos y tetraedros. Por ejemplo, el 2-símplice $\sigma = \operatorname{conv}\{u_0, u_1, u_2\}$ de la Figura 2.1 es un triángulo, y sus caras son los tres vértices, las tres aristas y el propio σ.

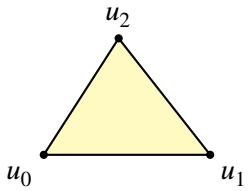


Figura 2.1: Un 2-símplice.

Definición 2.2 ([11, §III.1]). *Un* complejo simplicial *es una colección finita* K *de símplices tal que (i) si* $\sigma \in K$ *y* $\tau \leq \sigma$*, entonces* $\tau \in K$*; y (ii) la intersección de dos símplices de* K *es vacía o una cara común de ambos. Su* espacio subyacente $|K|$ *es la unión de sus símplices con la topología heredada de* $\mathbb{R}^d$*. Un* subcomplejo *es un complejo simplicial* $L \subseteq K$*.*

La condición (i) dice que el complejo está cerrado por caras y la (ii) que los símplices no se cortan de forma impropia. Es frecuente trabajar con el complejo simplicial abstracto: una familia finita de conjuntos cerrada por subconjuntos. Todo complejo abstracto de dimensión d admite una realización geométrica en $\mathbb{R}^{2d+1}$ [11, §III.1], así que ambos puntos de vista son equivalentes.

Ejemplo 2.3. El complejo K de la Figura 2.2 está formado por dos triángulos, abc y bcd, que comparten la arista bc, y una arista de, junto con todas sus caras. Cumple las dos condiciones de la definición: contiene las caras de cada uno de sus símplices, y dos símplices cualesquiera se cortan en una cara común (los triángulos, en la arista bc; el triángulo bcd y la arista de, en el vértice d). Su versión abstracta es la familia de conjuntos de vértices

$$\begin{aligned}\big\{&\{a\},\{b\},\{c\},\{d\},\{e\},\\ &\{a,b\},\{a,c\},\{b,c\},\{b,d\},\{c,d\},\{d,e\},\\ &\{a,b,c\},\{b,c,d\}\big\},\end{aligned}$$

que está cerrada por subconjuntos. En cambio, dos triángulos que se cortaran en un punto interior de una arista de uno de ellos no formarían un complejo simplicial, porque su intersección no sería una cara de ambos.

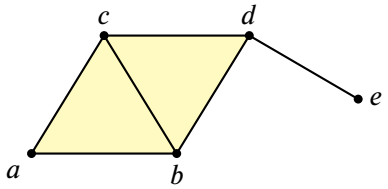


Figura 2.2: Un complejo simplicial con dos triángulos que comparten una arista y una arista colgante. Ilustración propia.

2.1.2 Complejos cúbicos

Una imagen es una rejilla de píxeles, y triangularla añade diagonales artificiales. Por eso los métodos que estudiamos usan *complejos cúbicos*, cuyas celdas son cuadrados alineados con la rejilla. Toda la teoría de esta sección se traslada sin cambios importantes a este contexto [18].

Definición 2.4 ([18, cap. 2]). *Un* intervalo elemental *es un intervalo* $[k, k+1]$ *(no degenerado) o* $[k,k]$ *(degenerado) con* $k \in \mathbb{Z}$. *Un* cubo elemental *en* $\mathbb{R}^2$ *es un producto* $Q = I_1 \times I_2$ *de intervalos elementales; su dimensión es el número de factores no degenerados. Así, los cubos de dimensión* $0, 1, 2$ *son vértices, aristas y cuadrados. Una* cara *de* Q *es un cubo elemental* Q' *con* $Q' \subseteq Q$*; lo denotamos* $Q' \leq Q$*, como en el caso simplicial. Un* complejo cúbico *es una colección finita* K *de cubos elementales tal que*

$$Q \in K \text{ y } Q' \leq Q \Rightarrow Q' \in K,$$

es decir, cerrada por caras.

Observación 2.5. A diferencia de los complejos simpliciales, aquí no hace falta exigir que dos celdas se corten en una cara común: se cumple automáticamente. La intersección de dos intervalos elementales es vacía o un intervalo elemental. Como $(I_1 \times I_2) \cap (J_1 \times J_2) = (I_1 \cap J_1) \times (I_2 \cap J_2)$, la intersección de dos cubos elementales es vacía o un cubo elemental, que es cara de ambos.

El ejemplo fundamental es el *complejo de rejilla* $K^{m,n}$, formado por todos los cubos elementales contenidos en $[1, m] \times [1, n]$ (Figura 2.3).

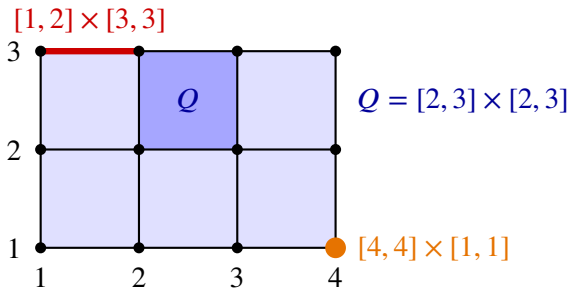


Figura 2.3: Complejo de rejilla $K^{4,3}$: los cubos elementales contenidos en $[1, 4] \times [1, 3]$. Tiene 12 vértices, 17 aristas y 6 cuadrados. Se destacan un cuadrado Q, una arista y un vértice. Su característica de Euler es $12 - 17 + 6 = 1$, la de un disco.

2.1.3 Imágenes como complejos filtrados

Sea $I \in \mathbb{R}^{m \times n}$ una imagen en escala de grises. Para estudiar su topología con homología persistente (Sección 2.3) no basta con un único complejo, necesitamos una familia creciente de complejos que recorra la imagen nivel a nivel. Para ello asignamos a cada celda del complejo de rejilla un valor $f_I(\sigma)$, que indica en qué momento entra en la familia. Fijado un umbral r, nos quedamos con las celdas de valor menor o igual que r. Al subir r, la imagen se va «escaneando»: primero aparecen los píxeles más oscuros, después los intermedios y, al final, la imagen completa. Para que cada paso de este escaneo sea un complejo, y no un conjunto de celdas sueltas, la función f_I debe construirse con cuidado. Hay dos formas estándar de hacerlo [27]:

- **Construcción V.** Cada píxel es un *vértice* de $K^{m,n}$ y recibe su intensidad; cada arista o cuadrado recibe el *máximo* de los valores de sus vértices.

- **Construcción T.** Cada píxel es un *cuadrado* (celda de dimensión 2) y recibe su intensidad; cada arista o vértice recibe el *mínimo* de los valores de los cuadrados que lo contienen.

En ambos casos la función $f_I : K \to \mathbb{R}$ resultante es *monótona*: $f_I(\tau) \leq f_I(\sigma)$ siempre que $\tau \leq \sigma$. Esta propiedad será clave en la Sección 2.3, porque garantiza que los conjuntos de subnivel son subcomplejos.

Ejemplo 2.6. Consideremos la imagen 2×2

$$I = \begin{pmatrix} 1 & 4 \\ 3 & 2 \end{pmatrix}$$

con la construcción V. Los cuatro píxeles son los vértices de un cuadrado y reciben su intensidad. Cada arista recibe el máximo de sus dos vértices: la superior vale $\max(1,4) = 4$, la inferior $\max(3,2) = 3$, la izquierda $\max(1,3) = 3$ y la derecha $\max(4,2) = 4$. El cuadrado recibe el máximo de los cuatro, 4. La función es monótona: el valor de cada arista es al menos el de sus vértices, y el del cuadrado, al menos el de sus aristas.

Los conjuntos de subnivel $K_r = f_I^{-1}(-\infty, r]$ son subcomplejos (Figura 2.4):

- K_2 contiene solo los vértices de valor 1 y 2. Son píxeles diagonales y ninguna arista los une, así que K_2 tiene dos componentes conexas.
- K_3 añade el vértice de valor 3 y las dos aristas de valor 3. Ambas tienen sus extremos en K_3, y las dos componentes anteriores quedan unidas en un camino.
- K_4 es el complejo completo.

Si, en cambio, asignáramos a la arista inferior el valor 1, la función dejaría de ser monótona y K_1 contendría esa arista pero no sus extremos, de valores 3 y 2: no sería un subcomplejo.

Observación 2.7. La elección de construcción fija qué píxeles se consideran conectados. Dos píxeles pueden ser vecinos por un lado (*4-conectividad*) o también por una esquina (*8-conectividad*). En la construcción V los píxeles son vértices y solo los unen aristas horizontales y verticales, así que dos píxeles diagonales quedan separados: el primer plano se conecta con 4-conectividad (como en K_2 del ejemplo anterior). En la construcción T los píxeles son cuadrados y dos cuadrados diagonales comparten el

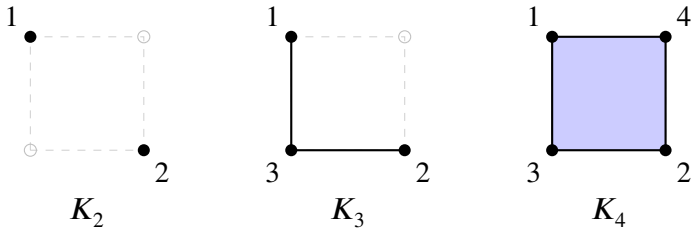


Figura 2.4: Conjuntos de subnivel de la construcción V de la imagen $\left(\begin{smallmatrix}1 & 4\\ 3 & 2\end{smallmatrix}\right)$. En K_2 los dos píxeles diagonales forman dos componentes; en K_3 quedan unidos; en K_4 está el complejo completo.

vértice de la esquina: el primer plano se conecta con 8-conectividad. La diferencia es relevante para estructuras finas y oblicuas. Una línea diagonal de tres píxeles,



forma tres componentes con 4-conectividad y una sola con 8-conectividad.

2.2 Homología

La homología formaliza la idea de «agujero» de forma computable. Lo hace de manera indirecta: en lugar de describir el agujero, estudia lo que lo *rodea*. Hay agujeros de cada dimensión. En dimensión 0, la homología detecta las *componentes conexas*, es decir, los «huecos» que separan unas piezas de otras. En dimensión 1 detecta los *túneles* o lazos, como el agujero de un anillo. En dimensión 2 detecta las *cavidades*, como el interior hueco de una esfera, y así sucesivamente. Exponemos la teoría para un complejo simplicial K; para complejos cúbicos basta sustituir «símplice» por «cubo» [18].

2.2.1 Cadenas, ciclos y bordes

Definición 2.8 ([11, §IV.1]). *Una p-*cadena *es una suma formal $c = \sum_i a_i \sigma_i$ de p-símplices de K con $a_i \in \mathbb{F}_2$. Las p-cadenas forman un $\mathbb{F}_2$-espacio vectorial $C_p(K)$ cuya base son los p-símplices.*

Como los coeficientes son 0 o 1, una cadena es simplemente un conjunto de p-símplices, y la suma de dos cadenas es su diferencia simétrica.

Definición 2.9 ([11, §IV.1]). *El* borde *de un p-símplice $\sigma = [u_0, \dots, u_p]$ es la suma de sus caras de dimensión $p-1$,*

$$\partial_p \sigma = \sum_{j=0}^{p} [u_0, \dots, \widehat{u_j}, \dots, u_p],$$

donde $\widehat{u_j}$ indica que se omite u_j. Extendido por linealidad, define el operador borde *$\partial_p : C_p(K) \to C_{p-1}(K)$. La sucesión*

$$\cdots \xrightarrow{\partial_{p+2}} C_{p+1}(K) \xrightarrow{\partial_{p+1}} C_p(K) \xrightarrow{\partial_p} C_{p-1}(K) \xrightarrow{\partial_{p-1}} \cdots$$

es el complejo de cadenas *de K.*

Dos tipos de cadenas son especialmente relevantes. Un *p-ciclo* es una cadena sin borde, y un *p-borde* es una cadena que es el borde de algo:

$$Z_p(K) = \ker \partial_p, \qquad B_p(K) = \operatorname{im} \partial_{p+1}.$$

Lema 2.10 (Lema fundamental de la homología [11, §IV.1]). $\partial_p \circ \partial_{p+1} = 0$ para todo p.

Intuitivamente, cada cara de dimensión $p-1$ de un $(p+1)$-símplice aparece en el borde de exactamente dos de sus p-caras, y en $\mathbb{F}_2$ se cancela.

En consecuencia $B_p(K) \subseteq Z_p(K)$: todo borde es un ciclo. El recíproco falla precisamente cuando hay agujeros. Un ciclo que rodea un hueco no puede rellenarse, y por tanto no es borde de nada.

2.2.2 Grupos de homología y números de Betti

Definición 2.11 ([11, §IV.1]). *El* p-ésimo grupo de homología *de K es el cociente*

$$H_p(K) = Z_p(K) / B_p(K),$$

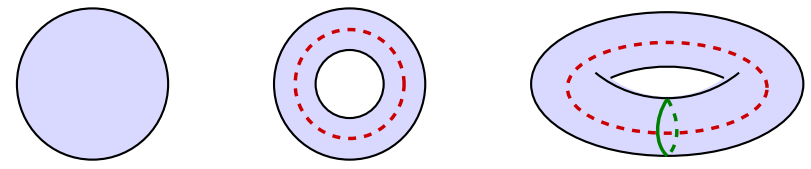
y el p-ésimo número de Betti *es su dimensión, $\beta_p(K) = \dim H_p(K) = \dim Z_p(K) - \dim B_p(K)$.*

Observación 2.12. Sobre $\mathbb{F}_2$, estos «grupos» son en realidad espacios vectoriales. Como ∂_p es lineal, $Z_p(K)$ y $B_p(K)$ son subespacios de $C_p(K)$, y su cociente $H_p(K)$ es un espacio vectorial con una dimensión bien definida. Por eso la homología puede calcularse con álgebra lineal (Sección 2.2.4).

Los elementos de $H_p(K)$ son clases $c + B_p(K)$ de ciclos que difieren en un borde; dos ciclos de la misma clase se llaman *homólogos*. En el plano, que es el caso que nos ocupa, solo interesan dos números de Betti:

- β_0 cuenta las **componentes conexas**: dos vértices son homólogos si y solo si los une un camino de aristas.
- β_1 cuenta los **agujeros** (ciclos independientes que no rodean ninguna región rellena).

Ejemplo 2.13 ([11, §IV.1]). Si K triangula un disco, $\beta_0 = 1$ y $\beta_p = 0$ para $p \geq 1$. Si triangula un anillo (o un círculo), $\beta_0 = \beta_1 = 1$. Para el toro, $\beta_0 = 1$, $\beta_1 = 2$ y $\beta_2 = 1$: los dos generadores de H_1 dan la vuelta al «brazo» y al «agujero» del toro (Figura 2.5).



Disco $\beta_0 = 1,\ \beta_1 = 0$ | Anillo $\beta_0 = 1,\ \beta_1 = 1$ | Toro $\beta_0 = 1,\ \beta_1 = 2,\ \beta_2 = 1$

Figura 2.5: Números de Betti de tres espacios. En rojo discontinuo, un ciclo que rodea un agujero y genera H_1; en el toro, en verde, el segundo generador, que da la vuelta al brazo. En el disco todo ciclo es borde, y H_1 es trivial.

Observación 2.14 (Homología reducida [11, §IV.1]). Todo complejo no vacío tiene al menos una componente conexa, por lo que siempre $\beta_0 \geq 1$. En algunas aplicaciones conviene que el caso base, una única componente, tenga número de Betti 0, de modo que β_0 cuente los «huecos» que separan componentes y no las componentes en sí. Para ello se añade al complejo de cadenas la *aplicación de aumento* $\varepsilon : C_0(K) \to \mathbb{F}_2$, definida por $\varepsilon(u) = 1$ en cada vértice u y extendida por linealidad:

$$\cdots \xrightarrow{\partial_2} C_1(K) \xrightarrow{\partial_1} C_0(K) \xrightarrow{\varepsilon} \mathbb{F}_2 \to 0.$$

Los grupos de homología de este complejo aumentado son la *homología reducida* $\tilde{H}_p(K)$. Solo cambia la dimensión 0: ahora los 0-ciclos son las cadenas con un número par de vértices, y

$$\tilde{\beta}_0 = \beta_0 - 1, \qquad \tilde{\beta}_p = \beta_p \quad (p \geq 1).$$

Así, un disco o un punto tienen toda su homología reducida trivial.

2.2.3 Inclusiones inducidas

Sea $K' \subseteq K$ un subcomplejo. La *inclusión* $\iota : K' \hookrightarrow K$ deja cada símplice en su lugar. Como las caras de un símplice de K' también están en K', la inclusión lleva cadenas en cadenas, $\iota_\# : C_p(K') \to C_p(K)$, y conmuta con el operador borde. Por tanto lleva ciclos en ciclos y bordes en bordes, y pasa al cociente:

$$\iota_* : H_p(K') \to H_p(K).$$

Esta aplicación dice qué clases de K' sobreviven en K y cuáles se vuelven triviales o se identifican entre sí. Al ser lineal, queda descrita por su núcleo y su conúcleo,

$$\ker \iota_* = \{x : \iota_*(x) = 0\}, \qquad \operatorname{coker} \iota_* = H_p(K)/\operatorname{im} \iota_*.$$

En nuestro contexto, $\dim \ker \iota_*$ cuenta las clases que *mueren* al pasar de K' a K, y $\dim \operatorname{coker} \iota_*$ las clases de K que *no proceden* de K'. Esta pareja reaparecerá en la métrica DIU de la Sección 2.6.1. Para enunciar en qué sentido la homología es un invariante necesitamos precisar cuándo dos espacios «tienen la misma forma».

Definición 2.15 ([14, cap. 0]). *Dos aplicaciones continuas $f, g : X \to Y$ son* homótopas *si existe una aplicación continua $H : X \times [0,1] \to Y$ con $H(\cdot,0) = f$ y $H(\cdot,1) = g$; es decir, si f se puede deformar en g de forma continua. Una aplicación $f : X \to Y$ es una* equivalencia homotópica *si existe $g : Y \to X$ tal que $g \circ f$ y $f \circ g$ son homótopas a la identidad; en ese caso decimos que X e Y son* homotópicamente equivalentes. *Un subespacio $A \subseteq X$ es un* retracto por deformación *de X si existe una homotopía $H : X \times [0,1] \to X$ con $H(\cdot,0) = \mathrm{id}_X$, $H(\cdot,1)(X) \subseteq A$ y $H(a,t) = a$ para todo $a \in A$ y todo t.*

Un retracto por deformación es la forma más visual de equivalencia homotópica: X se «encoge» sobre A sin romperse ni pegarse, y sin mover los puntos de A. Por ejemplo, un anillo se retrae por deformación sobre su circunferencia central, y un disco sobre su centro. En ambos casos la inclusión $A \hookrightarrow X$ es una equivalencia homotópica: el anillo tiene la homología de una circunferencia y el disco, la de un punto. Encoger o estirar un espacio de esta manera no crea ni destruye componentes ni agujeros.

Teorema 2.16 (Invariancia homotópica [14, Teor. 2.27 y Cor. 2.11]). *La homología simplicial de K es isomorfa a la homología (singular) de su espacio subyacente $|K|$, por lo que no depende de la triangulación elegida. Además, toda equivalencia homotópica $f : X \to Y$ induce isomorfismos $f_* : H_p(X) \to H_p(Y)$ para todo p. En particular, espacios homotópicamente equivalentes tienen los mismos números de Betti.*

Proposición 2.17 (Euler–Poincaré [11, §IV.2]). Sea n_p el número de p-símplices de K. La *característica de Euler* $\chi(K) = \sum_{p\geq 0}(-1)^p n_p$ verifica

$$\chi(K) = \sum_{p\geq 0}(-1)^p \beta_p(K).$$

Combinando ambos resultados, χ solo depende del espacio y no del complejo que lo triangula: es un invariante topológico. Por ejemplo, el complejo de rejilla de la Figura 2.3 tiene $\chi = 1$, igual que un disco o un punto.

2.2.4 Cálculo mediante reducción matricial

Como $Z_p = \ker \partial_p$ y $B_p = \operatorname{im} \partial_{p+1}$, los números de Betti dependen solo de los operadores borde. Si n_p es el número de p-símplices, el teorema del rango da $\dim \ker \partial_p = n_p - \operatorname{rank} \partial_p$, y por tanto:

Proposición 2.18 ([11, §IV.2]).

$$\beta_p = \dim Z_p - \dim B_p = n_p - \operatorname{rank} \partial_p - \operatorname{rank} \partial_{p+1}.$$

Para calcular la homología basta, pues, conocer los rangos de los operadores borde. Fijado un orden de los símplices, ∂_p se representa por la *matriz de borde*: una fila por cada $(p-1)$-símplice, una columna por cada p-símplice y un 1 en la posición (i, j) si el i-ésimo $(p-1)$-símplice es cara del j-ésimo p-símplice. Para obtener su rango es suficiente reducirla, por ejemplo, a su *forma normal de Smith* mediante operaciones elementales de filas y columnas: un bloque identidad en la esquina superior izquierda y ceros en el resto. El rango es el tamaño de ese bloque. El coste es como mucho cúbico en el número de símplices [11, §IV.2].

Ejemplo 2.19. Sea K el borde de un triángulo, con vértices a, b, c y aristas ab, bc, ac. Su matriz de borde ∂_1 (filas a, b, c; columnas ab, bc, ac) es

$$\partial_1 = \begin{pmatrix} 1 & 0 & 1 \\ 1 & 1 & 0 \\ 0 & 1 & 1 \end{pmatrix}.$$

Sumando a la tercera columna las dos primeras (en $\mathbb{F}_2$) se anula, porque $\partial_1(ab + bc + ac) = 0$, mientras que las dos primeras son independientes. Por tanto $\operatorname{rank} \partial_1 = 2$. Como no hay triángulos, $\partial_2 = 0$, y $\partial_0 = 0$ por definición. Aplicando la fórmula anterior:

$$\beta_0 = 3 - 0 - 2 = 1, \qquad \beta_1 = 3 - 2 - 0 = 1.$$

Es la homología de un círculo: una componente y un agujero, generado por el ciclo $ab + bc + ac$.

Si añadimos el triángulo abc a $\boldsymbol{K}$, su borde es la columna $\partial_2 = (1, 1, 1)^T$, de rango 1. Ahora

$$\beta_0 = 1, \qquad \beta_1 = 3 - 2 - 1 = 0, \qquad \beta_2 = 1 - 1 - 0 = 0,$$

la homología de un disco: el ciclo $ab + bc + ac$ es el borde del triángulo y deja de ser un agujero.

2.3 Homología persistente

Los números de Betti de un único espacio son muy sensibles al ruido: un píxel aislado crea una componente nueva. La homología persistente resuelve este problema estudiando una *familia* de espacios y midiendo cuánto dura cada característica topológica a lo largo de ella. Las características que persisten mucho se consideran significativas; las efímeras, ruido.

La idea se entiende mejor con un ejemplo en una dimensión. Pensemos en la gráfica de una función como en un paisaje que se va inundando: a medida que sube el nivel del agua a, el conjunto de subnivel $X_a = f^{-1}(-\infty, a]$ es la parte sumergida.

Ejemplo 2.20. Sea f la función lineal a trozos que toma los valores $4,\ 0,\ 6,\ 5,\ 8,\ 1,\ 10$ en siete puntos equiespaciados (Figura 2.6). Al subir el nivel a:

- En $a = 0$ aparece una componente en el mínimo de valor 0; en $a = 1$, otra en el mínimo de valor 1; en $a = 5$, una tercera. Cada mínimo local *hace nacer* una componente.
- En $a = 6$ el agua supera el collado que separa las componentes nacidas en 0 y en 5, y ambas se funden en una. Decimos que *muere* la más joven, la nacida en 5.
- En $a = 8$ se supera el segundo collado y se funden la componente nacida en 0 y la nacida en 1. Muere de nuevo la más joven, la nacida en 1.
- La componente nacida en 0 no muere nunca.

Cada componente queda descrita por su par (nacimiento, muerte): $(0, \infty)$, $(1, 8)$ y $(5, 6)$.

La decisión de qué componente muere en cada fusión sigue una regla fija [11, §VII.1]:

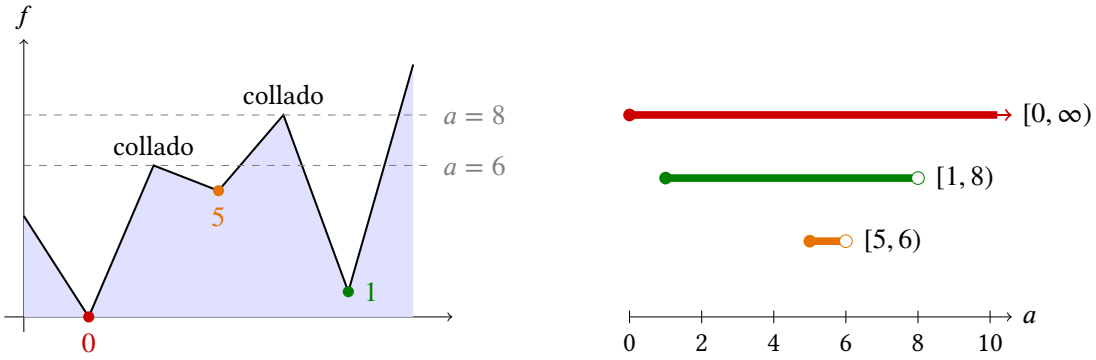


Figura 2.6: Izquierda: una función en una dimensión; al subir el nivel a nacen componentes en los mínimos y se funden en los collados. Derecha: el intervalo de vida de cada componente. La componente naranja vive muy poco: es un mínimo poco profundo, típico del ruido.

> **Regla del mayor** (*elder rule*). Cuando dos componentes se funden, continúa la más antigua (la que nació antes) y termina la más joven.

La *persistencia* de una componente es la diferencia entre su muerte y su nacimiento. En el ejemplo, la componente nacida en 1 persiste 7 unidades: es una estructura real del paisaje. La nacida en 5 persiste solo 1: es un pequeño hoyo que desaparece en cuanto el nivel sube un poco y, en una imagen, correspondería a ruido. Esta distinción entre lo que persiste y lo que no es la idea central de la homología persistente, que generaliza este procedimiento a todas las dimensiones (componentes, agujeros, etc.).

2.3.1 Filtraciones

Definición 2.21 ([11, §VII.1]). *Sea K un complejo y $f : K \to \mathbb{R}$ una función monótona. Si $a_1 < \cdots < a_n$ son los valores que toma f, los conjuntos de subnivel $K_i = f^{-1}(-\infty, a_i]$ son subcomplejos y forman la* filtración de subnivel

$$\emptyset = K_0 \subseteq K_1 \subseteq \cdots \subseteq K_n = K.$$

Para una imagen con la construcción V, la función monótona es exactamente la extensión por máximos de la Sección 2.1.3. En Edelsbrunner–Harer esta construcción recibe el nombre de *filtración lower star* [11, §VII.2].

Ejemplo 2.22. Sea K el complejo con vértices a, b, c y aristas ab y bc, y sea f dada por $f(a) = 1$, $f(c) = 2$, $f(b) = 3$ y $f(ab) = f(bc) = 3$. La función es monótona: cada vértice tiene un valor no mayor que el de las aristas que lo contienen. Sus conjuntos de subnivel son $K_1 = \{a\}$, $K_2 = \{a, c\}$ y $K_3 = K$. K_2 es un subcomplejo aunque a y c no estén conectados: no contiene aristas.

Ejemplo 2.23. Sea I una imagen de 1×4 píxeles con intensidades $0, 5, 1, 4$ de izquierda a derecha, con la construcción V sobre un camino de cuatro vértices. Al subir el umbral a se van añadiendo píxeles y aristas, y cada componente de $\{I \leq a\}$ se registra al nacer y al fusionarse. El píxel de intensidad 0 nace en $a = 0$, y el de intensidad 1 en $a = 1$. Al llegar a $a = 5$, el píxel central de intensidad 5 une ambas regiones; por la regla del mayor, la componente nacida en 1, la más joven, muere en 5. Así, $\mathrm{Dgm}_0 = \{(0, \infty), (1, 5)\}$ más la diagonal (Figura 2.7). El píxel de intensidad 4 se une a su vecino en el mismo paso en que nace, así que no aporta ningún punto con persistencia positiva.

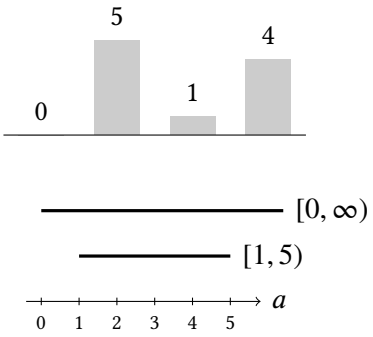


Figura 2.7: Arriba, las intensidades del ejemplo anterior en orden de izquierda a derecha. Abajo, el código de barras de H_0 sobre el eje de umbrales a: el intervalo $[0, \infty)$ corresponde a la componente que nunca muere, y $[1, 5)$ a la que nace en la intensidad 1 y muere al unirse en $a = 5$. Los puntos de la diagonal se omiten. Ilustración propia.

Observación 2.24 (Filtraciones de supernivel [27, §3]). En segmentación interesa el primer plano, es decir, los píxeles con probabilidad *alta*. Por eso se usan conjuntos de *supernivel* $f^{-1}[a, +\infty)$, lo que equivale a la filtración de subnivel de $-f$ (o de $1 - f$ si f es una probabilidad). Toda la teoría se aplica sin cambios.

2.3.2 Grupos persistentes y diagramas

Cada inclusión $K_i \subseteq K_j$, $i \leq j$, induce una aplicación $f_p^{i,j} : H_p(K_i) \to H_p(K_j)$, y la filtración da lugar a una sucesión

$$0 = H_p(K_0) \to H_p(K_1) \to \cdots \to H_p(K_n) = H_p(K).$$

Definición 2.25 ([11, §VII.1]). *Los* grupos de homología persistente *son las imágenes* $H_p^{i,j} = \operatorname{im} f_p^{i,j}$, *y los* números de Betti persistentes *son sus dimensiones,* $\beta_p^{i,j} = \dim H_p^{i,j}$.

$H_p^{i,j}$ contiene las clases de K_i que siguen vivas en K_j. Una clase $\gamma \in H_p(K_i)$ *nace* en K_i si no está en $H_p^{i-1,i}$. Si nace en K_i, *muere* al entrar en K_j si se fusiona con una clase más antigua en ese paso, que es de nuevo la regla del mayor. Su persistencia es $a_j - a_i$, y es infinita si la clase no muere nunca.

Definición 2.26 ([11, §VII.1]). *Sea* $\mu_p^{i,j}$ *el número de clases independientes de dimensión* p *que nacen en* K_i *y mueren al entrar en* K_j*:*

$$\mu_p^{i,j} = \left(\beta_p^{i,j-1} - \beta_p^{i,j}\right) - \left(\beta_p^{i-1,j-1} - \beta_p^{i-1,j}\right).$$

El diagrama de persistencia $\operatorname{Dgm}_p(f)$ *es el multiconjunto formado por los puntos* (a_i, a_j), *con* $i < j$ *y* $\mu_p^{i,j} > 0$, *cada uno con multiplicidad* $\mu_p^{i,j}$*; los puntos* (a_i, ∞), *uno por cada clase independiente que nace en* K_i *y no muere nunca; y los puntos de la diagonal, con multiplicidad infinita.*

Todos los puntos están por encima de la diagonal, y la distancia vertical de cada punto a ella es su persistencia. Los puntos cercanos a la diagonal son ruido y los alejados, estructura. Los puntos de la diagonal se añaden por razones técnicas: permiten emparejar diagramas con distinto número de puntos (Sección 2.4).

Teorema 2.27 (Lema fundamental de la homología persistente [11, §VII.1]). *Para todo* $0 \leq k \leq l \leq n$ *y toda dimensión* p*,*

$$\beta_p^{k,l} = \sum_{i \leq k} \sum_{j > l} \mu_p^{i,j}.$$

Es decir, el diagrama codifica *toda* la información de la homología persistente: $\beta_p^{k,l}$ es el número de puntos en el cuadrante superior izquierdo con vértice (a_k, a_l) [11, §VII.1].

Observación 2.28 (Códigos de barras y módulos de persistencia [7], [27, §2.3]). Una forma equivalente de representar el diagrama es el *código de barras* (*barcode*): cada punto (b, d) se dibuja como un intervalo $[b, d)$, como en las Figuras 2.6 y 2.7. Algebraicamente, la familia de espacios $H_p(K_i)$ con las aplicaciones $f_p^{i,j}$ es un *módulo de persistencia*. Todo módulo de persistencia de dimensión finita en cada punto se descompone de forma única como suma directa de módulos intervalo [7]; el multiconjunto de esos intervalos es su código de barras.

2.3.3 Algoritmo de reducción

Se ordenan los m símplices de forma *compatible*: $\sigma_1, \dots, \sigma_m$ con $i < j$ si $f(\sigma_i) < f(\sigma_j)$ o si σ_i es cara de σ_j. Se construye la matriz de borde total ∂, de tamaño $m \times m$ y con todas las dimensiones juntas. Sea $\mathrm{low}(j)$ el índice de fila del 1 más bajo de la columna j. El algoritmo suma columnas de izquierda a derecha hasta que no haya dos columnas no nulas con el mismo low:

$R = \partial$
para $j = 1, \dots, m$:
  mientras exista $j' < j$ con $\mathrm{low}(j') = \mathrm{low}(j)$:
    sumar la columna j' a la columna j

Teorema 2.29 (Lema de emparejamiento [11, §VII.1]). *Los pares* $(\mathrm{low}(j), j)$ *de la matriz reducida* R *no dependen de la reducción concreta. Además, si* $i = \mathrm{low}(j)$ *y* σ_i *tiene dimensión* p*, entonces* $(a_i, a_j) \in \mathrm{Dgm}_p(f)$*. Si la columna* i *es nula y ninguna columna tiene su* 1 *más bajo en la fila* i*, entonces* $(a_i, \infty) \in \mathrm{Dgm}_p(f)$*.*

La interpretación es directa. Si la columna j queda a cero, σ_j es *positivo*: crea un ciclo nuevo y hace nacer una clase. Si no queda a cero, σ_j es *negativo*: mata la clase que nació con $\sigma_{\mathrm{low}(j)}$. El coste en el peor caso es cúbico en m [11, §VII.1].

Ejemplo 2.30 ([11, §VII.1]). Sea K un triángulo con sus caras, filtrado añadiendo primero los tres vértices v_1, v_2, v_3, luego las aristas $e_4 = v_1v_2$, $e_5 = v_2v_3$, $e_6 = v_1v_3$ y por último el triángulo t_7, con $f(\sigma_i) = i$. Al reducir ocurre lo siguiente:

- e_4 mata la componente nacida en v_2, y su punto es $(2, 4)$.
- e_5 mata la nacida en v_3, y su punto es $(3, 5)$.
- La columna de e_6 se anula ($e_4 + e_5 + e_6$ es un ciclo), así que e_6 hace nacer un 1-ciclo.

- t_7 mata ese 1-ciclo, y su punto es $(6, 7)$.

La componente de v_1 nunca muere. Por tanto $\mathrm{Dgm}_0 = \{(1, \infty), (2, 4), (3, 5)\}$ y $\mathrm{Dgm}_1 = \{(6, 7)\}$.

2.3.4 Árboles de fusión y *union-find* en dimensión 0

El algoritmo de reducción sirve en cualquier dimensión, pero su coste en el peor caso es cúbico. En dimensión 0 hay una vía mucho más rápida, que es la que aprovecha Topograph (Sección 2.6.1).

Árbol de fusión [11, §VII.1]. Si dibujamos cada componente de X_a como un punto y seguimos su evolución al subir a, obtenemos un grafo: las ramas nacen en los mínimos y se unen en los collados. Como las componentes se fusionan pero nunca se dividen, el grafo no tiene ciclos y es un árbol, el *árbol de fusión* (*merge tree*). En el ejemplo de la Figura 2.6 tiene tres hojas, en los mínimos 0, 1 y 5, y dos uniones, en los collados 6 y 8. La regla del mayor descompone el árbol en caminos disjuntos: en cada unión continúa la rama más antigua y termina la más joven. Cada camino es un punto del diagrama: $(0, \infty)$, $(1, 8)$ y $(5, 6)$. Esta es la única descomposición en caminos cuyo número de caminos que atraviesan $[a, b]$ coincide, para todo $a \leq b$, con el número de componentes de X_b que contienen puntos de X_a. Por eso el diagrama de dimensión 0 es un resumen del árbol de fusión, pero no lo determina por completo: pierde, por ejemplo, con qué rama se funde cada componente al morir.

Cálculo con *union-find* [11, §VII.2]. Recorriendo las celdas en orden de filtración, el árbol se construye con una estructura *union-find*, que mantiene una partición de los vértices en componentes. Cada vértice crea una componente nueva. Cada arista uw puede hacer dos cosas:

- si u y w están en componentes distintas, las fusiona, y por la regla del mayor muere la componente cuyo vértice más antiguo es más reciente;
- si están en la misma componente, no cambia H_0: cierra un ciclo, es decir, hace nacer una clase de dimensión 1.

Etiquetando cada componente con su vértice más antiguo, cada paso cuesta tiempo casi constante, y Dgm_0 se obtiene en $O(m\,\alpha(m))$ una vez ordenadas las celdas, donde α es la inversa de la función de Ackermann (en la práctica, una constante).

Por qué solo en dimensión 0. *Union-find* funciona porque en dimensión 0 las clases de homología son exactamente los bloques de una partición: dos vértices son homólogos si y solo si están en la misma componente, y añadir una arista solo puede unir dos bloques. En dimensión 1 no hay nada parecido. Las clases son elementos de un espacio vectorial, un ciclo puede ser suma de otros, y cuando un triángulo (o un cuadrado) mata una clase no basta con unir dos conjuntos: hay que decidir *qué combinación* de ciclos muere. Por eso en dimensiones superiores hace falta el álgebra lineal de la reducción matricial. Por la misma razón, la historia de los ciclos no forma un árbol.

Dimensión 1 en el plano por dualidad [11, §VII.2]. En una superficie hay una salida: los agujeros de los subniveles de f corresponden a componentes de los subniveles de $-f$ (es decir, de los superniveles de f). En concreto, un punto finito (a, b) está en $\mathrm{Dgm}_1(f)$ si y solo si $(-b, -a)$ está en $\mathrm{Dgm}_0(-f)$. Así, en imágenes bidimensionales también Dgm_1 se calcula con *union-find*. Es la misma idea, la dualidad entre agujeros del primer plano y componentes del fondo, que explota Topograph (Sección 2.6.1).

2.4 Distancias entre diagramas y estabilidad

Para usar diagramas de persistencia como métrica o como pérdida hay que compararlos. Un *emparejamiento* entre dos diagramas D_1, D_2 es una biyección $\gamma : D_1 \to D_2$. Gracias a los puntos de la diagonal siempre existe: un punto sin pareja se empareja con su proyección sobre la diagonal.

Definición 2.31 ([11, §VIII.2]). *La* distancia de cuello de botella *y la* distancia de Wasserstein *de orden q son*

$$d_B(D_1, D_2) = \inf_{\gamma} \sup_{x \in D_1} \|x - \gamma(x)\|_\infty, \qquad W_q(D_1, D_2) = \left(\inf_{\gamma} \sum_{x \in D_1} \|x - \gamma(x)\|_\infty^q \right)^{1/q},$$

donde el ínfimo recorre todos los emparejamientos.

Teorema 2.32 (Estabilidad [6], [11, §VIII.2]). *Para funciones f, g sobre el mismo complejo, $d_B(\mathrm{Dgm}_p(f), \mathrm{Dgm}_p(g)) \le \|f - g\|_\infty$.*

La intuición es la siguiente. Si dos imágenes I y J difieren en cada píxel como mucho en ε, las funciones monótonas que inducen sobre el complejo también difieren como mucho en ε en cada celda, porque el máximo (o el mínimo) de valores que cambian poco cambia poco. Es decir, $\|f_I - f_J\|_\infty \leq \varepsilon$. El teorema garantiza entonces que los diagramas también están cerca: cada punto se desplaza como mucho ε en cada coordenada, y los únicos puntos que pueden aparecer o desaparecer son los cercanos a la diagonal, con persistencia menor que 2ε. En resumen, pequeños cambios en la imagen producen pequeños cambios en la función monótona y, por tanto, pequeños cambios en el diagrama de persistencia. En el ejemplo de la Figura 2.6, un ruido de amplitud pequeña puede crear o eliminar componentes efímeras como la nacida en 5, pero no la nacida en 1, que persiste 7 unidades.

Observación 2.33. El emparejamiento óptimo de d_B o W_q solo mira las *coordenadas* de los puntos, es decir, los valores de nacimiento y muerte, y no *dónde* está cada característica en la imagen. Dos agujeros en posiciones distintas pero con la misma persistencia son indistinguibles. Esta limitación es una de las motivaciones de Topograph (Sección 2.6.1).

2.5 Dice y clDice

Las pérdidas de solapamiento y las pérdidas topológicas parten de la misma idea: comparar la predicción con la referencia a través de sus conjuntos de píxeles. Esta sección describe dos medidas que aparecen en el resto del trabajo: el coeficiente de Dice, que cuenta píxeles, y clDice, que cuenta píxeles sobre el esqueleto de cada forma y por tanto es sensible a su conectividad. Sean P la predicción binaria y G la referencia, ambas subconjuntos del dominio de píxeles Ω, y $|\cdot|$ el número de elementos de un conjunto.

2.5.1 Coeficiente de Dice

Definición 2.34 ([9]). *El* coeficiente de Dice *entre P y G es*

$$\mathrm{Dice}(P, G) = \frac{2\,|P \cap G|}{|P| + |G|} \in [0, 1].$$

Dice vale 1 cuando $P = G$ y 0 cuando ambos conjuntos son disjuntos. Si $J = |P \cap G|/|P \cup G|$ es la intersección sobre unión (IoU), se cumple $\mathrm{Dice} = 2J/(1 + J)$:

las dos medidas ordenan las predicciones de la misma manera, pero como funciones de pérdida ponderan los errores de forma distinta.

Para entrenar, la predicción es continua. Si $p_i \in [0,1]$ es la probabilidad del píxel i y $g_i \in \{0,1\}$ su etiqueta, la pérdida de Dice es

$$\mathcal{L}_{\text{Dice}} = 1 - \frac{2\sum_i p_i\, g_i + \varepsilon}{\sum_i p_i + \sum_i g_i + \varepsilon},$$

con $\varepsilon > 0$ para evitar divisiones por cero. La baseline del trabajo combina esta pérdida con la entropía cruzada binaria (BCE).

Dice cuenta píxeles. No distingue un puente de dos píxeles que une dos filamentos de un hueco de dos píxeles que parte uno, aunque ambos errores cambien por completo el número de objetos. Esa limitación motiva el resto de la sección.

2.5.2 Esqueleto y clDice

El esqueleto de una forma es una versión fina, centrada en ella, que conserva su conectividad. Se obtiene con la erosión, que quita una capa de píxeles del borde, y la apertura, que erosiona y después dilata para eliminar detalles más finos que el elemento estructurante. Para que el esqueleto pueda usarse como pérdida, Shit et al. [24] emplean versiones blandas de estas operaciones sobre mapas $I \in [0,1]^{\Omega}$, en las que el mínimo y el máximo locales sustituyen a la erosión y la dilatación binarias:

$$\text{er}(I) = \text{mín}\big(\min_{3\times1} I,\ \min_{1\times3} I\big), \qquad \text{di}(I) = \max_{3\times3} I, \qquad \text{op}(I) = \text{di}\big(\text{er}(I)\big).$$

Definición 2.35 ([24, Sec. 3]). *Sea I un mapa de probabilidades y $K \in \mathbb{N}$ el número de iteraciones. El* esqueleto blando *de orden K es $S_K(I)$, definido por*

$$\begin{aligned} x_0 &= I, & S_0 &= \text{ReLU}\big(I - \text{op}(I)\big), \\ x_k &= \text{er}(x_{k-1}), & S_k &= S_{k-1} + \text{ReLU}\big(\delta_k - S_{k-1}\,\delta_k\big), \quad \delta_k = \text{ReLU}\big(x_k - \text{op}(x_k)\big), \end{aligned}$$

para $k = 1, \dots, K$.

Cada erosión sucesiva elimina capas del objeto, y en cada paso se guarda lo que la apertura del mapa erosionado no recupera: las crestas que aún no han desaparecido. Así, el esqueleto blando aproxima el esqueleto de una forma sin necesidad de valores binarios.

Definición 2.36 ([24]). *Sean $S(P)$ y $S(G)$ los esqueletos de la predicción y de la referencia. Las medidas de precisión y exhaustividad topológicas son*

$$T_{\text{prec}} = \frac{|S(P) \cap G|}{|S(P)|}, \qquad T_{\text{sens}} = \frac{|S(G) \cap P|}{|S(G)|},$$

y clDice *es su media armónica:*

$$\text{clDice}(P, G) = \frac{2\, T_{\text{prec}}\, T_{\text{sens}}}{T_{\text{prec}} + T_{\text{sens}}}.$$

T_{prec} mide si el esqueleto de la predicción cae dentro de la referencia: un puente entre dos filamentos crea esqueleto fuera de G y reduce T_{prec}. T_{sens} mide si el esqueleto de la referencia queda cubierto por la predicción: un filamento partido deja trozos de $S(G)$ sin cubrir y reduce T_{sens}. Así, clDice penaliza los dos errores topológicos que Dice no distingue.

Para entrenar, se usan mapas blandos p (probabilidades) y g (etiquetas) y las intersecciones se convierten en sumas sobre píxeles, con un suavizado unitario como en nuestra implementación:

$$\mathcal{L}_{\text{clDice}} = 1 - \text{clDice}(p, g), \qquad T_{\text{prec}} = \frac{\sum_i S(p)_i\, g_i + 1}{\sum_i S(p)_i + 1}, \qquad T_{\text{sens}} = \frac{\sum_i S(g)_i\, p_i + 1}{\sum_i S(g)_i + 1}.$$

Hay tres matices. Primero, clDice es una aproximación local: el esqueleto no garantiza que los números de Betti de la predicción coincidan con los de la referencia, por lo que no ofrece garantías topológicas formales. Segundo, el número de iteraciones K es un hiperparámetro que decide hasta qué grosor el esqueleto blando se comporta como un esqueleto; usamos $K = 10$ en todos los experimentos. Tercero, clDice por sí solo no mide la extensión del objeto: sin un término de solapamiento, la pérdida puede llegar a soluciones degeneradas. Esto lo comprobamos experimentalmente en el Capítulo 6, donde la combinación de entropía cruzada y clDice sin Dice colapsa.

2.6 Topología en la segmentación de imágenes

En esta sección denotamos por $L \in [0,1]^{m \times n}$ el mapa de probabilidades que predice la red, por $P \in \{0,1\}^{m \times n}$ su binarización y por $G \in \{0,1\}^{m \times n}$ la segmentación de referencia. El error de números de Betti, $|\beta_p(P) - \beta_p(G)|$, es la métrica topológica más

sencilla [27, App. K], pero ignora la localización: una predicción con el número correcto de componentes, todas en el lugar equivocado, obtiene error cero. A continuación describimos Topograph, que sí tiene en cuenta dónde está cada componente.

2.6.1 Topograph

Una forma natural de llevar la homología persistente al entrenamiento es comparar los diagramas de persistencia de la predicción y de la referencia y usar su distancia como pérdida [16, 27]. Estas pérdidas tienen tres inconvenientes [21]. Primero, el emparejamiento entre diagramas solo mira las coordenadas de los puntos y puede asociar características situadas en lugares distintos de la imagen (Sección 2.4). Segundo, el coste: hay que calcular los diagramas en cada iteración del entrenamiento, lo que en la práctica limita su uso a parches pequeños. Tercero, el gradiente es muy disperso: cada punto (b, d) del diagrama depende solo de dos píxeles, el de nacimiento y el de muerte. Topograph [21] sustituye la persistencia por un grafo de componentes conexas, que tiene en cuenta la posición, se calcula en tiempo casi lineal y reparte el gradiente sobre regiones enteras.

Grafo de componentes [21, §2.1]. Se modela la imagen binaria con la construcción T, es decir, con 8-conectividad (Observación 2.7), y se añade una celda de fondo exterior $c^\star$ pegada al borde, con lo que el complejo resultante $\tilde{C}$ es homeomorfo a la esfera S^2. Primer plano $F(I)$ y fondo $B(I)$ se descomponen en componentes conexas $F_1, \dots, F_k$ y $B_1, \dots, B_l$. El *grafo de componentes* $\mathcal{G}(I)$ tiene un vértice por componente y una arista entre F_i y B_j si se tocan. Es un árbol bipartito y determina los números de Betti del primer plano:

$$\beta_0(F) = k, \qquad \beta_1(F) = \sum_{i=1}^{k} \big(\deg F_i - 1\big).$$

En la segunda fórmula, cada fondo vecino de F_i salvo el exterior es un agujero de F_i (Figura 2.8).

Grafo combinado [21, §2.1]. Sean P la predicción binaria y G la referencia, vistas como regiones del plano mediante la construcción T. Para evitar problemas de conectividad en los bordes, sus primeros planos se engrosan ligeramente: $F_\varepsilon(P)$ es el de la predicción engrosado en ε y $F_{2\varepsilon}(G)$ el de la referencia engrosado en 2ε. Superponiéndolos, el plano se cubre con cuatro regiones: verdaderos positivos, $\mathrm{TP} = F_\varepsilon(P) \cap F_{2\varepsilon}(G)$

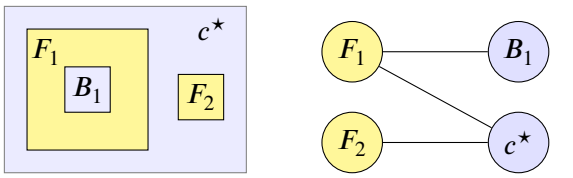
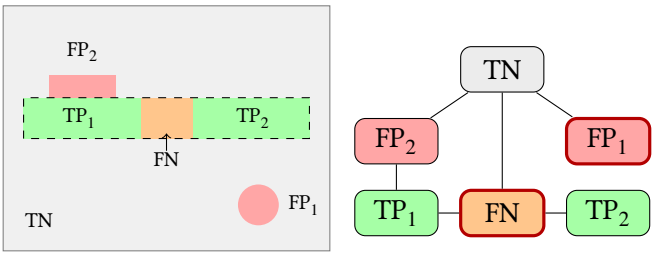


Imagen binaria Grafo de componentes

Figura 2.8: Una imagen binaria con dos componentes de primer plano: F_1 tiene un agujero B_1 y F_2 no. En su grafo de componentes, $\beta_0 = 2$ y $\beta_1 = (2-1)+(1-1) = 1$. Ilustración propia.

(filamento en ambas); falsos positivos, FP (filamento solo en la predicción); falsos negativos, FN (filamento solo en la referencia), y verdaderos negativos, TN (fondo en ambas). Las componentes conexas de las cuatro regiones son los vértices del *grafo combinado* $\mathcal{G}(P, G)$, con aristas entre regiones adyacentes. Es bipartito: las aristas unen siempre una región correcta (TP o TN) con una errónea (FP o FN) (Figura 2.9).



Predicción y referencia Grafo combinado

Figura 2.9: La referencia es una barra (contorno discontinuo); la predicción la parte en dos (hueco FN), sobresale un poco por arriba (FP_2) y añade una mancha espuria (FP_1). En el grafo combinado, FP_2 tiene un vecino TP y uno TN, así que es regular: solo desplaza un borde. FN (dos vecinos TP) y FP_1 (ningún vecino TP) son críticos, marcados con borde grueso: el primero parte el filamento y el segundo crea una componente nueva. Por simplicidad no se dibuja el engrosamiento, que separa siempre las regiones TP de las TN con una franja fina de error; por eso el grafo no tiene aristas entre TP y TN. Ilustración propia.

Vértices regulares y críticos [21, §2.2–2.3]. Un vértice erróneo $v \in V_F$ es *regular* si tiene exactamente un vecino TP y exactamente un vecino TN:

$$V_r = \{v \in V_F \,:\, \exists!\, s \in N(v),\ s \subseteq \mathrm{TP} \ \wedge\ \exists!\, t \in N(v),\ t \subseteq \mathrm{TN}\}.$$

Corregir un vértice regular solo desplaza una frontera y no cambia la topología, así que su error es irrelevante para la forma. Los vértices *críticos* son el resto, $V_c = V_F \setminus V_r$, y la pérdida se concentra en ellos:

$$\mathcal{L}_{CG} = \alpha \sum_{v \in V_c} \bar{y}_v,$$

donde $\bar{y}_v$ es la probabilidad media de la clase predicha en los píxeles de v. La predicción binaria P con la que se construye el grafo se obtiene tomando en cada píxel la clase más probable, lo que en segmentación binaria equivale a umbralizar la probabilidad en 0,5. Esa binarización no es diferenciable, pero no hace falta que lo sea: el grafo solo decide qué regiones son críticas, y el gradiente fluye a través de $\bar{y}_v$. A diferencia de las pérdidas basadas en persistencia, actúa sobre *todos* los píxeles de cada región crítica.

Proposición 2.37 ([21, Prop. 2.1]). Si $\mathcal{L}_{CG}(P, G) = 0$, todas las inclusiones del diagrama

$$F_\varepsilon(P) \hookleftarrow F_\varepsilon(P) \cap F_{2\varepsilon}(G) \hookrightarrow F_{2\varepsilon}(G), \qquad F_\varepsilon(P),\ F_{2\varepsilon}(G) \hookrightarrow F_\varepsilon(P) \cup F_{2\varepsilon}(G)$$

son retractos por deformación y, en particular, equivalencias homotópicas (Definición 2.15).

La proposición dice más que la igualdad de los números de Betti de P y G. Como la intersección y la unión tienen la misma topología que ambas, cada componente y cada agujero de la predicción se corresponde con uno de la referencia *en la misma posición*: es la correspondencia espacial que el emparejamiento de diagramas no garantiza (Sección 2.4).

Métrica DIU [21, §2.5]. La *discrepancia entre intersección y unión* usa la aplicación inducida por la inclusión $i : F_\varepsilon(P) \cap F_{2\varepsilon}(G) \hookrightarrow F_\varepsilon(P) \cup F_{2\varepsilon}(G)$:

$$\xi^{\mathrm{err}} = \dim \ker i_* + \dim \operatorname{coker} i_*.$$

Por dualidad de Alexander, los agujeros del primer plano se corresponden con componentes del fondo. Si j es la inclusión análoga para los fondos,

$$\xi^{\mathrm{err}} = \dim \ker i_0 + \dim \operatorname{coker} i_0 + \dim \ker j_0 + \dim \operatorname{coker} j_0,$$

de modo que basta contar componentes conexas. Intuitivamente, el conúcleo cuenta componentes de la unión sin contrapartida en la intersección y el núcleo cuenta componentes de la intersección que en la unión se funden en una sola.

Complejidad [21, §2.6]. Construir $\mathcal{G}(P, G)$ requiere etiquetar componentes conexas, lo que con *union-find* cuesta $O(n\,\alpha(n))$. Como el grafo es plano, tiene $O(n)$ aristas, y clasificar los vértices es lineal. Es la misma estructura que hace eficiente el cálculo de Dgm_0 (Sección 2.3.4), pero sin necesidad de ordenar una filtración.

2.6.2 Comparación

La Tabla 2.1 resume las pérdidas que aparecen en el capítulo: la de solapamiento (Dice), la basada en esqueletos (clDice), las basadas en diagramas de persistencia y Topograph.

	Dice	clDice [24]	Persistencia [16, 27]	Topograph [21]
Compara	píxeles	esqueletos	diagramas	grafo de comp.
Sensible a la topología	no	sí	sí	sí
Garantías formales	no	no	sí	sí
Correspondencia esp.	—	local	no*	sí
Soporte del gradiente	todos los px	esqueletos	2 px/caract.	regiones críticas
Coste	$O(n)$	$O(Kn)$	alto	$O(n\,\alpha(n))$

Tabla 2.1: Comparación de las pérdidas descritas en el capítulo. n es el número de píxeles y K el número de iteraciones del esqueleto blando. *Betti matching [27] añade correspondencia espacial a costa de un cálculo aún más caro.

3 Contexto del problema

El objetivo central del trabajo es estudiar qué aporta la topología a la segmentación de estructuras finas: cómo se miden las formas, cómo se usan como funciones de pérdida y qué mejoran frente a las pérdidas de solapamiento. Para ponerlas a prueba necesitamos un caso práctico con estructuras finas y errores topológicos claros. Este capítulo presenta ese caso: la detección de filamentos solares. Describimos primero qué son los filamentos y por qué interesa detectarlos (Sección 3.1), después el conjunto de datos MAGFiLO (Sección 3.2) y la competición en la que se enmarca el trabajo, con su métrica de evaluación (Sección 3.3), y revisamos los trabajos previos de detección automática (Sección 3.4). Terminamos con las dificultades específicas del problema (Sección 3.5), que son en buena parte topológicas.

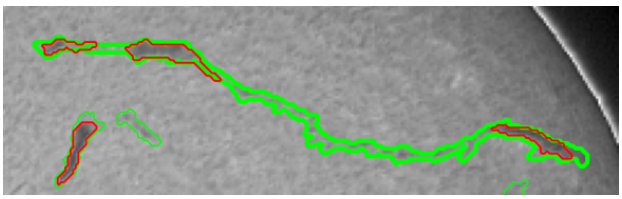
3.1 Filamentos solares

Los filamentos son nubes de plasma unas cien veces más frío y denso que la corona que los rodea, en la que permanecen suspendidos; en su sujeción desempeña un papel principal el campo magnético [22, §1.1]. Se sitúan siempre sobre las líneas de inversión de polaridad del campo magnético de la fotosfera [22, §1, §2.1]. Vistos sobre el disco solar en la línea H-alfa (656,3 nm), absorben la radiación del fondo y aparecen como estructuras oscuras. En el limbo, el borde del disco, aparecen brillantes y reciben el nombre de *protuberancias* [22, §1].

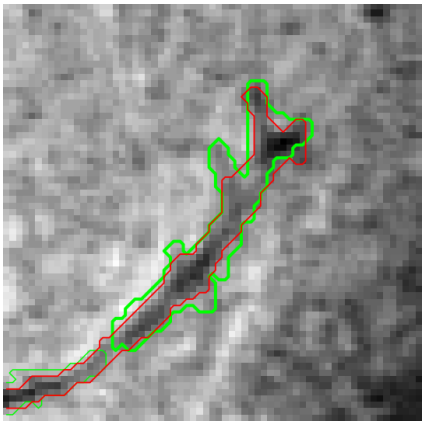
Morfológicamente, un filamento consta de una *espina*, que recorre su eje, de la que salen extensiones laterales llamadas *barbas* [22, §2.1]. Su *quiralidad* es el sentido de giro, dextrógiro o levógiro, del campo magnético a lo largo de ese eje. No se observa directamente en H-alfa, pero se deduce de las barbas: según el lado hacia el que se separan de la espina, el filamento es dextrógiro o levógiro [22, §2.4.1].

Su interés práctico es el clima espacial. Los filamentos pueden desestabilizarse y entrar en erupción, asociados a fulguraciones y eyecciones de masa coronal [22, §1.1, §5]. Una eyección dirigida hacia la Tierra puede dañar la red eléctrica, alterar los sistemas GPS y suponer un riesgo de radiación para tripulaciones y astronautas [2]. Detectar y caracterizar los filamentos de forma automática y precisa es, por tanto, un paso previo para su seguimiento y para la predicción de erupciones.

Observaciones GONG. Las imágenes proceden de la red GONG (*Global Oscillation Network Group*), un conjunto de seis observatorios terrestres repartidos en longitud para observar el Sol de forma casi continua [13]: Big Bear (B), Cerro Tololo (C), Learmonth (L), Mauna Loa (M), El Teide (T) y Udaipur (U). La letra entre paréntesis es la que identifica la estación en el nombre de cada fichero. Al ser observaciones terrestres, están afectadas por la turbulencia atmosférica, las nubes y artefactos instrumentales, y su calidad varía entre estaciones y días.



(a) Fragmentado con hueco real.



(b) Fusionado.

Figura 3.1: Dos errores típicos de segmentación sobre observaciones H-alfa de GONG, con la referencia en verde y la predicción en rojo. (a) Un filamento partido en varios trozos separados por huecos reales. (b) Dos filamentos de la referencia (el pequeño, abajo a la izquierda, y el principal) unidos en una única predicción.

3.2 El conjunto de datos MAGFiLO

MAGFiLO (*Manually Annotated GONG Filaments in H-alpha Observations*) es un conjunto de datos de filamentos anotados manualmente sobre observaciones H-alfa de

GONG [1]. Su versión 1.0 contiene 10 244 filamentos anotados en 958 observaciones entre 2011 y 2022. Para cada filamento incluye la máscara de segmentación, la caja contenedora mínima, la espina (la línea que recorre su eje principal) y la quiralidad (el sentido de giro de su campo magnético, deducido de las barbas; Sección 3.1).

La anotación supuso más de 1 000 horas-persona, con un proceso de revisión doble ciego: cada observación fue anotada por hasta tres anotadores independientes, y cada anotación, revisada después por separado [1]. El acuerdo entre anotadores sobre la quiralidad se mide con el estadístico κ de Cohen [5], que compara el acuerdo observado con el que cabría esperar por azar ($\kappa = 0$: acuerdo casual; $\kappa = 1$: acuerdo perfecto). El valor obtenido, $\kappa = 0{,}66$, se considera un acuerdo «sustancial» [1]. Para las máscaras, que son lo que se evalúa en este trabajo, el artículo no da una medida de acuerdo; la estimamos en la Sección 4.1.

Subconjunto de la competición. La competición usa solo las máscaras de segmentación [2]. El conjunto de entrenamiento público está organizado por *pares anotador–imagen*: cada imagen aparece tantas veces como anotadores la hayan etiquetado, cada vez con su propio conjunto de filamentos. La Tabla 3.1 resume sus características.

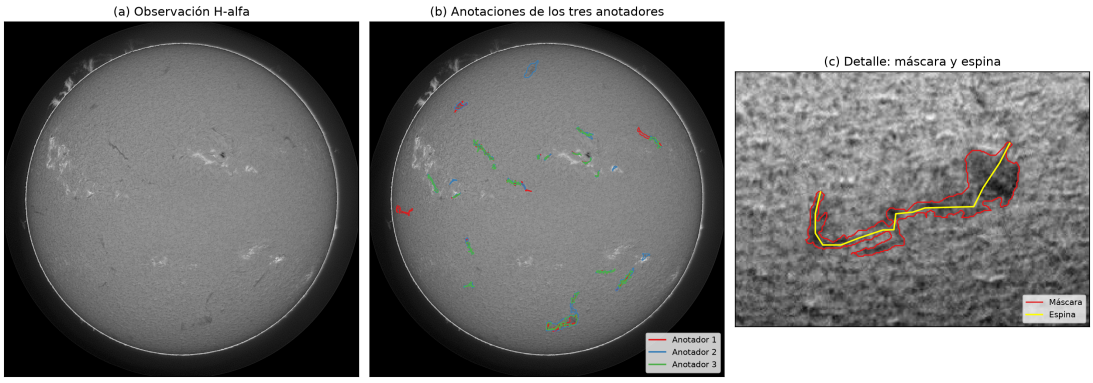


Figura 3.2: Una observación del conjunto de entrenamiento. (a) Imagen H-alfa de disco completo. (b) Anotaciones de los tres anotadores que la etiquetaron, una por color: coinciden en los filamentos grandes y difieren en los pequeños y en la extensión de cada uno. (c) Detalle de un filamento con su máscara y la espina anotada.

Las imágenes son de disco completo, de 2048×2048 píxeles [2]. Las seis estaciones están representadas de forma equilibrada, entre 102 y 127 imágenes cada una. La distribución temporal no lo está: la mayoría de las imágenes son de 2011–2017, y los años 2018–2022 aportan pocas observaciones. Además, de un mismo día suele haber

Imágenes distintas	707
Pares anotador–imagen	1 154
imágenes con 1 / 2 / 3 anotadores	411 / 145 / 151
Filamentos anotados (sumando anotadores)	8 199
Filamentos por par (media)	7,1
Periodo	2011–2022
Resolución	2048×2048

Tabla 3.1: Conjunto de entrenamiento público de la competición, calculado a partir del fichero de anotaciones.

varias observaciones, tomadas desde estaciones distintas, que muestran prácticamente el mismo Sol. Este hecho obliga a separar entrenamiento y validación por fecha y no por imagen, como se explica en el Capítulo 5.

El conjunto de test es oculto. Solo se dispone de sus imágenes, y las predicciones se evalúan en la plataforma.

3.3 La competición *Solar Filament Segmentation Challenge 2026*

El trabajo se enmarca en el *Solar Filament Segmentation Challenge 2026*, una competición de Kaggle organizada por el Earth-Space AI Research (ESAIR) Lab dentro de la IEEE BigData Cup 2026 [2]. Se lanzó el 10 de julio de 2026 y el plazo de entrega final es el 15 de noviembre de 2026.

Tarea. Se pide generar una máscara de segmentación para cada filamento *individual*, que capture toda su extensión, incluidas las estructuras finas como las barbas, y que incluya el menor número posible de píxeles ajenos al filamento [2]. Se trata, por tanto, de un problema de *segmentación de instancias* de una sola clase. El envío es un fichero con una fila por filamento predicho, que contiene el identificador de la imagen y la máscara codificada en RLE a resolución original.

Métrica. La métrica principal es la *calidad panóptica* (*Panoptic Quality*, PQ) [19]. Inicialmente la competición usaba el coeficiente Dice, pero los organizadores lo sustituyeron por PQ el 7 de agosto de 2026 [2].

La métrica compara *segmentos*. Un segmento es el conjunto de píxeles que forman un único filamento, es decir, la máscara binaria de una instancia, en la referencia, cada filamento anotado; en la predicción, cada instancia que devuelve el modelo, que en este trabajo es una componente conexa de la máscara predicha (Sección 5.4). Así, una imagen con siete filamentos tiene siete segmentos de referencia, y el IoU entre dos segmentos se calcula sobre sus conjuntos de píxeles.

Definición 3.1 ([19]). *Sean Y el conjunto de segmentos de referencia e $\hat{Y}$ el de segmentos predichos. Un par $(y, \hat{y}) \in Y \times \hat{Y}$ es un* verdadero positivo *si* $\mathrm{IoU}(y, \hat{y}) > 0{,}5$*, donde*

$$\mathrm{IoU}(y, \hat{y}) = \frac{|y \cap \hat{y}|}{|y \cup \hat{y}|}.$$

Los segmentos predichos sin pareja son falsos positivos *(FP) y los de referencia sin pareja,* falsos negativos *(FN). La calidad panóptica es*

$$\mathrm{PQ} = \frac{\sum_{(y,\hat{y}) \in TP} \mathrm{IoU}(y, \hat{y})}{|TP| + \frac{1}{2}|FP| + \frac{1}{2}|FN|}.$$

El umbral $\mathrm{IoU} > 0{,}5$ tiene una consecuencia importante. Si los segmentos predichos no se solapan entre sí, cada segmento de referencia puede emparejarse como mucho con uno predicho, y viceversa. El emparejamiento es, por tanto, único y no requiere ningún algoritmo de asignación [19]. Además, PQ se factoriza como

$$\mathrm{PQ} = \underbrace{\frac{\sum_{TP} \mathrm{IoU}}{|TP|}}_{\mathrm{SQ}} \times \underbrace{\frac{|TP|}{|TP| + \frac{1}{2}|FP| + \frac{1}{2}|FN|}}_{\mathrm{RQ}},$$

donde la *calidad de segmentación* SQ es el IoU medio de los aciertos y mide lo bien delimitados que están. La *calidad de reconocimiento* RQ mide, en cambio, cuántos filamentos se detectan, sin mirar cómo de bien. Si llamamos *precisión* a la fracción de segmentos predichos que son aciertos, $P = |TP|/(|TP| + |FP|)$, y *exhaustividad* a la fracción de segmentos de referencia que se aciertan, $R = |TP|/(|TP| + |FN|)$, entonces

$$\mathrm{RQ} = \frac{2|TP|}{2|TP| + |FP| + |FN|} = \frac{2PR}{P + R},$$

es decir, RQ es la media armónica de P y R, la medida F_1 habitual en detección [19]. Es alta solo si el modelo encuentra la mayoría de los filamentos (R alta) sin inventar muchos (P alta).

En la competición, Y e $\hat{Y}$ contienen los segmentos de *todas* las imágenes. Es decir, se suman TP, FP, FN e IoU sobre todo el conjunto antes de dividir, y no se promedia imagen a imagen [2]. Como unidad de evaluación se usa el par anotador–imagen: las predicciones de una imagen se comparan por separado con la anotación de cada anotador. Por ejemplo, si una imagen tiene tres anotaciones, el mismo modelo se evalúa tres veces sobre esa imagen, una por cada anotador, y cada comparación aporta sus propios TP, FP y FN. Así, la evaluación no favorece a ningún anotador concreto, pero el desacuerdo entre ellos se traslada directamente a la métrica.

Como referencia de escala, los organizadores consideran que un PQ superior a 0,35 es un resultado de gran valor [2], esta cifra coincide con el acuerdo entre expertos. Si se comparan entre sí las anotaciones de distintos anotadores sobre una misma imagen, con la misma métrica, se obtiene un PQ de aproximadamente 0,34 (Sección 4.1.4). Un modelo que supere 0,35 se parece, por tanto, a cada anotador tanto como los anotadores se parecen entre sí. Es, por tanto, el umbral con el que conviene comparar nuestros resultados.

Rúbrica. La clasificación en el *leaderboard* es solo una parte de la evaluación final [2]:

- **Comparación cuantitativa (70 %):** PQ y las distribuciones de Dice, de IoU y de relaciones uno-a-varios y varios-a-uno entre segmentos predichos y de referencia. Estas últimas penalizan la *fragmentación* (un filamento predicho en varios trozos) y la *fusión* (varios filamentos predichos como uno).
- **Comparación cualitativa (30 %):** la descripción del pipeline completo, la morfología aparente de las predicciones y la calidad del código.

El *leaderboard* público se calcula con aproximadamente la mitad del conjunto de test; la otra mitad solo la ven los organizadores.

3.4 Trabajos previos en detección automática de filamentos

La detección automática de filamentos en imágenes H-alfa tiene una trayectoria de más de dos décadas. Podemos distinguir dos etapas.

Métodos clásicos. Los primeros métodos se basan en que los filamentos son más oscuros que su entorno, y los extraen con umbrales, operaciones morfológicas y reglas para descartar otras regiones oscuras. Un ejemplo representativo es el de Bernasconi et al. [4], que detecta, sigue y caracteriza filamentos, incluida su quiralidad a partir de las barbas. Estos métodos son interpretables y rápidos, pero dependen de umbrales ajustados a mano, son sensibles a las condiciones de observación y tienden a confundir filamentos con manchas solares y otras regiones oscuras [10].

Aprendizaje profundo. Con las redes convolucionales, el problema se ha abordado como segmentación semántica o de instancias. Zhu et al. [28] entrenan una U-Net [23] sobre imágenes H-alfa con máscaras obtenidas de forma semiautomática. Diercke et al. [10] proponen un método semisupervisado: un detector YOLOv5 entrenado con cajas anotadas a mano genera etiquetas aproximadas sobre el archivo de GONG, y con ellas entrenan una U-Net.

Un rasgo común de estos trabajos es la escasez de anotaciones manuales a nivel de píxel: la mayoría entrena con máscaras obtenidas por umbralización o por otros detectores, que heredan sus errores. MAGFiLO cubre precisamente esta carencia [1]. Sobre MAGFiLO, Solomon et al. [26] proponen EdgeAttNet, una U-Net con atención guiada por bordes en el cuello de botella, orientada a capturar mejor las barbas, y la comparan con una U-Net estándar entrenada con BCE + Dice.

Hasta donde conocemos, estos trabajos optimizan pérdidas de solapamiento píxel a píxel y se evalúan con métricas de solapamiento (precisión, exhaustividad, IoU). Ninguno incorpora restricciones topológicas al entrenamiento ni al post-procesado. Tampoco se habían evaluado con una métrica de instancias como PQ, que penaliza explícitamente la fragmentación y la fusión. Este es el hueco que aborda este trabajo.

3.5 Dificultades del problema

Los propios organizadores señalan tres dificultades principales [2] (ítems 1 a 3), a las que añadimos dos más (ítems 4 y 5):

1. **Estructuras finas.** Las barbas tienen pocos píxeles de anchura y contraste débil. Son las primeras en perderse, y su orientación es justo la que aporta información física.
2. **Ruido e imagen terrestre.** Distinguir el material del filamento de otras regiones oscuras (manchas, ruido, artefactos) no es trivial en observaciones afectadas por la atmósfera.
3. **Continuidad estructural.** Los algoritmos tienden a devolver filamentos *fragmentados* o a agrupar regiones oscuras cercanas en «islas», con resultados físicamente incoherentes.
4. **Desacuerdo entre anotadores.** Los anotadores no coinciden siempre en dónde empieza y acaba un filamento, ni en si dos trozos forman uno o dos filamentos. Esto fija un techo a lo que puede conseguir cualquier modelo frente a una anotación concreta. Lo cuantificamos con el PQ de un anotador frente a otro sobre la misma imagen, que es el techo humano de la métrica.
5. **Desequilibrio de clases.** Los filamentos ocupan una fracción muy pequeña de cada imagen, de modo que una pérdida píxel a píxel está dominada por el fondo.

Las dificultades 1 y 3 son, en el fondo, *topológicas*. Si las instancias se obtienen como componentes conexas de una máscara binaria, el número de filamentos predichos es el número de componentes conexas, es decir, el número de Betti β_0 de esa máscara. Un filamento partido en dos aumenta β_0: un acierto se convierte en un falso negativo y en dos falsos positivos, aunque falten solo unos pocos píxeles. Dos filamentos unidos por un puente de píxeles hacen el error contrario. Una barba perdida, en cambio, apenas cambia el IoU. Métricas como Dice o el propio IoU, que cuentan píxeles, son poco sensibles a estos errores, mientras que PQ y la rúbrica los penalizan con fuerza.

4 Planteamiento

Los capítulos anteriores han presentado las herramientas topológicas (Capítulo 2) y el problema práctico (Capítulo 3). Este capítulo explica cómo se combinan en el trabajo. El punto de partida no es proponer mejoras a ciegas, sino *diagnosticar* primero qué errores comete un modelo de referencia (Sección 4.1). Después se muestra que el post-proceso habitual tiene una lectura topológica directa: las instancias que produce son puntos de un diagrama de persistencia, y cada tipo de error deja en ese diagrama una firma reconocible (Sección 4.2). De esa lectura salen las hipótesis y las líneas de mejora del trabajo (Sección 4.3) y la forma de medir si una mejora funciona (Sección 4.4).

4.1 Diagnóstico de la baseline

El modelo de referencia, o *baseline*, es una U-Net entrenada con BCE + Dice. Para obtener instancias se umbraliza su mapa de probabilidades, se toman las componentes conexas y se descartan las de área menor que un mínimo. Los detalles se describen en el Capítulo 5. Lo que interesa aquí es *cómo* se equivoca este modelo.

4.1.1 Taxonomía de errores

El PQ solo distingue entre aciertos, falsos positivos y falsos negativos. Para decidir qué mejorar hace falta más detalle, así que se clasifica cada filamento de referencia y cada predicción según cómo se relacionan entre sí. Decimos que una predicción y un filamento de referencia están *relacionados* si su IoU es al menos 0,1 o si uno cubre al menos el 50 % del otro. El segundo criterio evita que un trozo pequeño de un filamento largo, cuyo IoU es bajo porque la unión es grande, se cuente como espurio en lugar de

como fragmento. Con esta relación, cada filamento de referencia no acertado, y cada predicción sin filamento, se clasifica en uno de los tipos de la Tabla 4.1.

Tipo	Descripción
Perdido	Ninguna predicción relacionada.
Fragmentado (1:n)	Relacionado con varias predicciones, que son sus trozos.
Fusionado (n:1)	Su predicción relacionada lo está también con otros filamentos.
Mal delimitado	Una sola predicción relacionada, pero con IoU $\leq 0{,}5$.
Espurio (predicción)	Predicción sin ningún filamento relacionado.

Tabla 4.1: Tipos de error considerados en el diagnóstico.

Tres de estos tipos son errores *topológicos* en un sentido preciso: cambian el número de componentes. Un filamento fragmentado en n trozos aporta n componentes donde debería haber una; n filamentos fusionados aportan una donde debería haber n, y un espurio aporta una componente que no existe en la referencia. En términos de la Sección 2.2, son discrepancias locales en β_0. Los perdidos y los mal delimitados, en cambio, no se deben a la conectividad de la predicción, sino a su presencia o a su forma.

La relación anterior es más exigente que la de las gráficas oficiales de la competición, que consideran relacionados una predicción y un filamento en cuanto se solapan (IoU > 0). En el Capítulo 6 los tipos de error se cuentan con la definición oficial, para que sean comparables con la rúbrica.

4.1.2 Recuperabilidad

Un error solo se puede corregir en el post-proceso si el mapa de probabilidades contiene la señal necesaria. Para los perdidos y los fragmentados se mide esa *recuperabilidad*:

- Para un filamento *perdido*, se mira la probabilidad máxima en su interior. Si es muy baja, el modelo no lo vio, y ningún post-proceso lo recuperará. Si queda algo por debajo del umbral, la señal existe.
- Para un filamento *fragmentado*, se calcula su *collado*: el umbral más alto al que sus trozos quedan unidos por un camino dentro del filamento. Si el collado está justo por debajo del umbral, basta con bajarlo un poco para que los trozos se

unan. Un collado de 0 indica un hueco real en la predicción, que ningún umbral cierra.

El collado es una noción topológica: es el valor del punto de silla en el que se funden las componentes de los trozos, es decir, el valor de *muerte* de las componentes más jóvenes en la filtración de superniveles restringida al filamento (Sección 2.3). La Sección 4.2 desarrolla esta conexión.

4.1.3 Dónde falla el modelo

Este diagnóstico se hizo con una primera versión de la baseline, entrenada antes de fijar el protocolo del Capítulo 5. Sus cifras no son comparables con las del Capítulo 6, pero sirvieron para decidir la estrategia. El análisis sobre la validación muestra cuatro patrones:

- La exhaustividad cae en los filamentos pequeños (25 %), en los cercanos al borde del disco solar (el limbo, 15 %) y en los que ningún otro anotador marca (14 %, frente al 68 % de los que marcan todos).
- Muchos filamentos sí se detectan, pero los elimina el filtro de área mínima: 203 filamentos de validación se pierden solo por él.
- Los espurios tienen casi la misma confianza que los aciertos (probabilidad máxima mediana de 0,917 frente a 0,933), así que la confianza por sí sola no los separa.
- Aproximadamente el 54 % de los espurios los marca otro anotador de la misma imagen. Más que errores del modelo, son desacuerdos entre anotadores.

Los tres primeros patrones son los que motivan este trabajo. El filtro de área elimina filamentos reales, y la confianza no sirve para distinguir los espurios, así que hace falta otro criterio para decidir qué componentes conservar. Ese criterio puede ayudar también con los filamentos pequeños que se pierden por el filtro de área o por quedar bajo el umbral (Sección 4.2), aunque no todas las pérdidas del primer patrón se deben al post-proceso. Algunos filamentos el modelo no llega a detectarlos, posiblemente porque a la resolución de entrada ocupan pocos píxeles o porque cerca del limbo cambia su aspecto, y otros son casos dudosos que los propios anotadores no marcan de forma consistente.

4.1.4 El techo humano

Comparando entre sí las anotaciones de las imágenes con varios anotadores, con el mismo PQ, se obtiene un acuerdo humano de PQ $\approx 0{,}34$. Esa primera baseline, comparada con cada anotador, obtiene $\approx 0{,}38$. El modelo se parece más a cada anotador que los anotadores entre sí, porque aprende una especie de consenso. Este dato es esencial para interpretar cualquier resultado: con referencias tan ruidosas, un PQ cercano a 1 no es alcanzable, y parte de los «errores» son desacuerdos entre expertos.

4.2 Lectura topológica del post-proceso

4.2.1 Instancias y diagrama de persistencia

Sea p el mapa de probabilidades que produce la red. Dado un umbral t, el post-proceso toma el conjunto de supernivel

$$X_t = \{x : p(x) > t\}$$

y declara que cada componente conexa de X_t es un filamento. Las componentes se calculan con 8-conectividad, es decir, con la construcción T (Observación 2.7), para no fragmentar artificialmente las barbas. Antes del filtro de área, el número de instancias predichas es, por tanto, $\beta_0(X_t)$.

En lugar de mirar un solo umbral, podemos considerar la filtración de superniveles completa, con t bajando de 1 a 0, y su diagrama de persistencia en dimensión 0 (Sección 2.3). Es la situación de la Figura 2.6 con el paisaje del revés: en vez de subir el nivel del agua, se baja el umbral. Cada componente *nace* en un máximo local de p, con valor b, y *muere* en $d < b$, cuando se funde en un collado con otra componente nacida antes, según la regla del mayor. La componente del máximo global no muere nunca, y le asignamos $d = -\infty$.

Proposición 4.1. Para todo umbral t, el número de instancias de la baseline antes del filtro de área es

$$\beta_0(X_t) = \#\{(b, d) \in \mathrm{Dgm}_0 : b > t \geq d\}.$$

Demostración (idea). Cada componente de X_t contiene un único máximo más antiguo, el de valor más alto (los empates se deshacen con un orden fijo de los píxeles). Por la regla del mayor, la componente que nació en ese máximo sigue viva en t: ya ha nacido,

porque $b > t$, y todavía no ha muerto, porque cualquier componente con la que se haya fundido era más joven, así que $d \leq t$. Las demás componentes nacidas dentro de esa región ya han muerto al fundirse con ella, con $d > t$. Hay, por tanto, una biyección entre las componentes de X_t y los puntos con $b > t \geq d$. Es el caso de dimensión 0 del resultado general según el cual β_p de un espacio de la filtración es el número de intervalos del código de barras que lo contienen [11, §VII.1].

Es decir, umbralizar en t equivale a quedarse con los puntos del diagrama en el cuadrante $\{b > t,\ d \leq t\}$, y el post-proceso deja de ser un ajuste de dos números para convertirse en una decisión sobre qué puntos del diagrama convertir en instancias.

Ejemplo 4.2. Sea p el perfil de probabilidad a lo largo de una línea de la imagen que toma los valores 0,05, 0,90, 0,45, 0,80, 0,10, 0,70, 0,05 (Figura 4.1). Los dos primeros máximos, A y B, pertenecen al mismo filamento, partido por una bajada de la probabilidad; el tercero, C, es una mancha sin filamento debajo. Al bajar el umbral:

- En $t = 0{,}90$ nace la componente de A; en $t = 0{,}80$, la de B; en $t = 0{,}70$, la de C.
- En $t = 0{,}45$ se supera el collado entre A y B, y sus componentes se funden. Muere la más joven, la de B.
- En $t = 0{,}10$ se supera el collado entre B y C, ya dentro de la componente de A, y muere la de C.

El diagrama es $\{(0{,}90, -\infty),\ (0{,}80, 0{,}45),\ (0{,}70, 0{,}10)\}$. Con $t = 0{,}5$, los tres puntos cumplen $b > t \geq d$, y la baseline produce tres instancias: el filamento aparece partido en dos y, además, hay un espurio.

4.2.2 La firma de cada error

Cada tipo de error de la Tabla 4.1 deja una firma reconocible en el diagrama (Tabla 4.2).

En el Ejemplo 4.2, el filamento fragmentado aparece como los puntos de A y B, y el collado que los separa es la muerte de B, $d = 0{,}45$, a solo 0,05 por debajo del umbral: bajando el umbral a 0,44 los dos trozos se unirían. El espurio C ilustra el segundo caso de la última fila: está aislado sobre un fondo bajo, de modo que su persistencia, $0{,}70 - 0{,}10 = 0{,}60$, es mayor que la de B, $0{,}80 - 0{,}45 = 0{,}35$, que es un trozo de un filamento real. La persistencia mide la robustez de una componente frente al umbral, no si corresponde a un filamento.

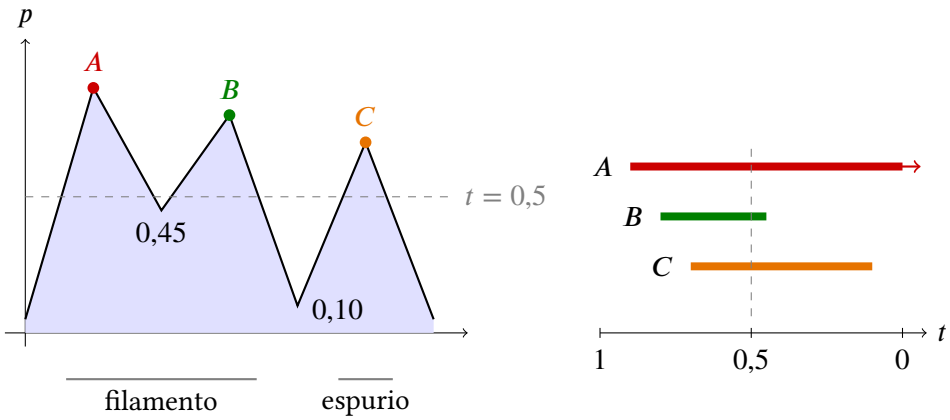


Figura 4.1: Izquierda: perfil de probabilidad del Ejemplo 4.2. Los máximos A y B son dos trozos del mismo filamento y C es una mancha espuria. Derecha: código de barras H_0 de la filtración de superniveles, con el umbral t bajando de izquierda a derecha. La línea discontinua en $t = 0{,}5$ corta las tres barras: la baseline produce tres instancias. Ilustración propia.

4.2.3 Área frente a persistencia

El filtro de área de la baseline es un criterio *geométrico*: descarta las componentes de X_t pequeñas, sea cual sea su punto en el diagrama. Dos componentes con el mismo par (b, d) pueden tener áreas muy distintas, así que el área no es una función del diagrama.

La persistencia ofrece un criterio *topológico*, con una justificación teórica. Por el teorema de estabilidad (Sección 2.4), si la predicción cambia en cada píxel como mucho en ε, los puntos del diagrama se desplazan como mucho ε, y solo pueden aparecer o desaparecer los de persistencia menor que 2ε. Las componentes poco persistentes son, por tanto, las que dependen de pequeñas fluctuaciones de la predicción, y las muy persistentes, las que sobreviven a ellas. Si los filamentos pequeños que elimina el filtro de área son robustos y los espurios no, un filtro por persistencia los separaría mejor.

El Ejemplo 4.2 muestra también el límite de esta idea: un espurio aislado sobre un fondo bajo es muy persistente. Cuál de los dos casos de la última fila de la Tabla 4.2 domina en la práctica es una pregunta empírica, que responde la Sección 6.3.

Observación 4.3. La filtración de superniveles de p y la de su *logit* $z = \log \frac{p}{1-p}$ son la misma, reparametrizada: como la sigmoide es estrictamente creciente, $\{p > t\} = \{z > \operatorname{logit}(t)\}$, y los diagramas tienen los mismos emparejamientos. Lo que cambia son

Error	Firma en el diagrama H_0 de superniveles
Fragmentado	Varios puntos del cuadrante nacidos dentro del mismo filamento. La muerte d de los más jóvenes es el collado entre trozos: si está justo por debajo de t, el hueco es recuperable bajando el umbral.
Fusionado	Los máximos de dos filamentos se unen en un collado por encima de t. El más joven muere antes de llegar al umbral ($d > t$), y en el cuadrante queda un solo punto para los dos.
Perdido	Ningún punto con $b > t$ dentro del filamento. Si hay uno con b algo menor que t, la señal existe pero queda por debajo del umbral.
Espurio	Un punto del cuadrante sin filamento debajo. Su persistencia depende del entorno: es baja si es un pequeño relieve sobre una zona de probabilidad intermedia, y alta si es una mancha aislada sobre un fondo cercano a 0.

Tabla 4.2: Firma de cada tipo de error en el diagrama de persistencia H_0 de la filtración de superniveles, para un umbral t.

los valores b y d y, con ellos, la persistencia $b - d$: la sigmoide comprime los valores cercanos a 0 y a 1, de modo que una diferencia pequeña en p puede ser grande en z. Por eso un umbral de persistencia τ solo tiene sentido referido a una escala. En este trabajo la persistencia se mide sobre p, para que τ se interprete en unidades de probabilidad.

4.3 Hipótesis y estrategia

Del diagnóstico y de la lectura topológica se derivan tres líneas de mejora, cada una dirigida a un tipo de error (Tabla 4.3). Se ordenan de menor a mayor coste: primero las que no requieren reentrenar.

Línea	Error al que apunta	Reentrena
E1. Umbral y área mínima	Espurios pequeños	No
E2. Post-proceso por persistencia	Fragmentación, espurios	No
E3. Pérdidas (IoU, clDice, Topograph)	Espurios, fragmentación, barbas	Sí

Tabla 4.3: Líneas de mejora, error al que apunta cada una y si requiere reentrenar el modelo.

E1. Ajuste del umbral y del área mínima. Se ajustan el umbral t y el área mínima de las componentes. Es la mejora más barata y sirve de segunda referencia para las demás. En el lenguaje de la sección anterior, el umbral elige el cuadrante del diagrama y el área mínima filtra sus puntos con un criterio geométrico.

E2. Post-proceso basado en persistencia. Sustituye el criterio geométrico por uno topológico. Parte de X_u, para un umbral u, y aplica dos operaciones:

- *Filtro por persistencia.* Se conserva una componente de X_u solo si contiene un máximo con persistencia $b-d \geq \tau$. En el Ejemplo 4.2, con $\tau = 0{,}5$ se conservarían las componentes de A y de C, y se eliminaría la de B.
- *Fusión por collado.* Las componentes conservadas que se unen en $X_{u-\delta}$, es decir, cuyo collado está a menos de δ por debajo del umbral, se cuentan como una sola instancia, sin añadir píxeles. Es la operación dirigida a los fragmentados recuperables, a costa de arriesgarse a crear fusiones. En el ejemplo, si $\tau \leq 0{,}35$, de modo que B se conserva, y $\delta > 0{,}05$, las componentes de A y B formarían una sola instancia.

El filtro se aplica antes de la fusión, de modo que un trozo poco persistente se elimina aunque esté cerca de otro robusto. También se estudia una variante, B2+P, que combina ambos criterios: conserva una componente si su área supera el mínimo o si su persistencia supera τ. Los parámetros se ajustan en validación.

Para el filtro no hace falta construir el diagrama completo. En morfología matemática, los *h-máximos* de una imagen son los máximos regionales que sobresalen al menos h por encima del collado más alto que los une a un máximo mayor [25]. Esa altura es exactamente la persistencia $b - d$ que asigna la regla del mayor, así que los h-máximos con $h = \tau$ son los nacimientos de los puntos con $b - d \geq \tau$. Se ha comprobado sobre imágenes sintéticas que la selección coincide con la del diagrama calculado con *union-find* (Sección 2.3.4). En ambos casos el coste es casi lineal en el número de píxeles, despreciable frente a la inferencia.

E3. Pérdidas con sesgo topológico. El post-proceso solo puede trabajar con la señal que el modelo ya produce. Para los fragmentados con hueco real, para los espurios muy seguros y para las barbas perdidas hay que cambiar lo que aprende la red. Se comparan tres alternativas a Dice:

- *IoU*, como control: es otra pérdida de solapamiento, sin sesgo topológico.
- *clDice* [24], que mide el solapamiento de los esqueletos (Sección 2.5). Premia la continuidad de las estructuras alargadas, lo que debería reducir la fragmentación y mejorar la detección de las barbas.
- *Topograph* [21], que compara las componentes de la predicción binarizada y de la referencia mediante el grafo combinado y penaliza solo las regiones críticas, las que cambian la topología (Sección 2.6.1). Actúa durante el entrenamiento sobre los mismos errores que la Tabla 4.2 lee en el diagrama: una componente espuria, un filamento partido o dos filamentos fusionados son discrepancias en el grafo combinado. La diferencia es que Topograph trabaja sobre un único umbral, el de la binarización ($p > 0{,}5$), mientras que el post-proceso elige el umbral y puede mirar el diagrama completo.

Hipótesis. Las líneas anteriores concretan cuatro hipótesis, que el Capítulo 6 contrasta:

H1. Los errores dominantes se deben a componentes que sobran o que faltan, por lo que un filtro sobre las componentes (E1) mejora mucho el PQ.
H2. La persistencia separa los filamentos pequeños de los espurios mejor que el área, y la fusión por collado repara parte de los fragmentados (E2).
H3. Una pérdida que penaliza las regiones topológicamente críticas reduce las componentes espurias y la fragmentación sin necesidad de post-proceso (E3, Topograph).
H4. Una pérdida que premia la continuidad del esqueleto mejora la detección de las barbas (E3, clDice).

Alcance. El cuarto patrón del diagnóstico, el desacuerdo entre anotadores, no se aborda en este trabajo. Podría tratarse cambiando cómo se construye la etiqueta de entrenamiento a partir de las varias anotaciones de cada imagen, y se recoge como trabajo futuro en el Capítulo 7.

4.4 Cómo medir una mejora

Una mejora del PQ global puede esconder que se arreglan unos filamentos y se rompen otros. Por eso cada versión se evalúa de tres formas:

1. **Métrica oficial:** PQ global, con SQ y RQ, y las distribuciones de la rúbrica (IoU, Dice y relaciones 1:n y n:1).
2. **Tipos de error:** cuántos filamentos quedan partidos, unidos o sin detectar, y cuántas predicciones no tocan ningún filamento. Los dos primeros miden los errores de estructura, las discrepancias locales en β_0, y los dos últimos, los errores de presencia. Se añade una medida específica de las barbas.
3. **Separación ajuste–reporte:** todas las decisiones (época, umbrales, parámetros del post-proceso) se toman en una mitad de la validación y la cifra se reporta en la otra, para no inflar los resultados.

El protocolo concreto se detalla en el Capítulo 5.

5 Metodología

Este capítulo describe el protocolo común a todos los experimentos: cómo se parten los datos, cómo se entrena y se elige cada modelo, cómo se obtienen las instancias y cómo se evalúan. Todas las ejecuciones siguen las mismas reglas, fijadas antes de empezar a comparar. Así, cualquier diferencia entre dos resultados se debe a la pieza que cambia (la pérdida, el post-proceso o los hiperparámetros) y no al protocolo. Cada una de las dos primeras corresponde a una de las líneas de mejora de la Sección 4.3, y cada medida de la evaluación, a un tipo de error de la Sección 4.1. El código está disponible en `https://github.com/AgustinG-git/tfm-filamentos` (Apéndice A).

5.1 Datos y partición

Se usa el conjunto de entrenamiento de la competición, con las anotaciones de MAGFiLO [1, 2]. El conjunto de test no tiene anotaciones públicas y solo se usa para enviar predicciones al *leaderboard*.

Partición por días. Las imágenes de un mismo día son casi idénticas: el Sol apenas cambia en unas horas. Si una imagen de un día estuviera en entrenamiento y otra del mismo día en validación, el modelo se evaluaría sobre algo que ya ha visto. Por eso la partición se hace por *fecha*: ningún día aparece en dos subconjuntos. Se reserva el 20 % de los días para validación, y estos se dividen a su vez en dos mitades, A y B (Tabla 5.1). La partición se genera una sola vez, con semilla fija, y se guarda junto al código.

Como todas las anotaciones de una imagen comparten fecha, una misma imagen nunca aparece en dos subconjuntos, ni siquiera anotada por anotadores distintos. En cambio, la partición no separa por anotador: de los 37 anotadores, todos los de

validación salvo uno aparecen también en entrenamiento. Separar por anotador mediría la generalización a anotadores nuevos, que no es el objetivo del trabajo; aquí se busca generalizar a días no vistos, con anotaciones del mismo proyecto.

Subconjunto	Días	Imágenes	Pares anotador–imagen
Entrenamiento	524	561	920
Validación A	66	72	113
Validación B	66	74	121

Tabla 5.1: Partición de los datos. La unidad de evaluación es el par anotador–imagen (Sección 3.3).

Ajuste en A, reporte en B. Toda decisión se toma en A: la época del modelo, los parámetros del post-proceso y los hiperparámetros. La cifra que se reporta es la de B, que no interviene en ninguna decisión. Si se eligiera en el mismo conjunto en el que se mide, la cifra estaría inflada: entre muchas variantes, alguna sale mejor por azar.

Preprocesado. Las imágenes H-alfa son de un canal y 2048×2048 píxeles. Para entrenar se reducen a 512×512 (interpolación por área), se replica el canal tres veces y se normalizan con la media y la desviación de ImageNet [8], porque el codificador viene preentrenado en ese conjunto. No se usan aumentos de datos.

Etiquetas. Cada anotación es un ejemplo de entrenamiento independiente: una imagen con tres anotadores aporta tres pares (imagen, máscara). La máscara de un par es la unión de los filamentos de ese anotador, reducida a 512×512. La referencia de evaluación, en cambio, son siempre las anotaciones originales, una por una y a resolución completa.

5.2 Modelo y entrenamiento

El modelo es una U-Net [23] con codificador ResNet-34 [15] preentrenado en ImageNet, de la biblioteca *Segmentation Models PyTorch* [17]. Produce un mapa de probabilidades p de una sola clase (filamento) a 512×512.

Salvo en el ajuste de la Sección 5.5, todas las ejecuciones usan la misma configuración: 30 épocas, lotes de 8, optimizador AdamW [20] con tasa de aprendizaje $3 \cdot 10^{-4}$ y *weight decay* 10^{-4}, y tasa de aprendizaje con decaimiento coseno. La red se ejecuta en precisión mixta, pero las pérdidas se calculan siempre en `float32`: en `float16` las sumas de clDice sobre un lote (unos $2 \cdot 10^6$ píxeles) desbordan. La semilla es 42; la baseline y Topograph se repiten además con la semilla 43.

Selección de la época. Al final de cada época se evalúa el modelo en A y se guarda el mejor. El criterio es fijo para todas las versiones: PQ global a 512×512, con umbral 0,5 y sin filtro de área. En el lenguaje de la Sección 4.2, las instancias evaluadas son las componentes de $X_{0,5}$, es decir, los puntos del diagrama con $b > 0{,}5 \geq d$ (Proposición 4.1). Se usa este post-proceso mínimo a propósito: si la época se eligiera con el post-proceso de cada versión, la comparación entre pérdidas mezclaría dos efectos.

5.3 Pérdidas

Todas las pérdidas incluyen BCE, con peso 0,5, y se obtienen cambiando una sola pieza respecto a la baseline (Tabla 5.2). IoU se definió en la Sección 3.3, Dice y clDice en la Sección 2.5 y Topograph en la Sección 2.6.1; aquí solo se fijan los pesos. IoU sirve de control sin sesgo topológico; clDice añade un sesgo hacia la continuidad del esqueleto, y Topograph, un sesgo hacia la topología de las componentes.

Nombre	Pérdida
Baseline	0,5 BCE + 0,5 Dice
IoU	0,5 BCE + 0,5 IoU
clDice	0,5 BCE + 0,25 Dice + 0,25 clDice
IoU+clDice	0,5 BCE + 0,25 IoU + 0,25 clDice
clDice sin Dice	0,5 BCE + 0,5 clDice
… + Topograph	la anterior $+ \alpha \, \mathcal{L}_{\text{Topo}}$, $\alpha = 0{,}04$

Tabla 5.2: Pérdidas comparadas. Cada una de las cinco primeras se entrena también con el término de Topograph.

clDice. Se usa el esqueleto blando de Shit et al. [24], con 10 iteraciones de erosión.

Topograph. Se usa la implementación oficial [21], con 8-conectividad, la misma que el post-proceso. Tres decisiones fijan cómo se añade:

- *Peso.* Con un modelo ya entrenado, el término de Topograph es unas 27 veces mayor que BCE+Dice. Con $\alpha = 0{,}04$ ambos pesan lo mismo. El valor se fija así y no se ajusta en las comparaciones de pérdidas.
- *Calentamiento.* Con un modelo sin entrenar, la predicción tiene cientos de regiones críticas por imagen y el término no aporta una señal útil. Por eso Topograph se activa a partir de la sexta época; en las cinco primeras $\alpha = 0$.
- *Binarización.* El grafo combinado se construye a partir de una predicción binaria, mientras que la red produce probabilidades. La implementación oficial binariza internamente tomando en cada píxel la clase más probable (*argmax*). La salida de un canal se le pasa como dos canales, $(0, z)$, con z el *logit*, de modo que la clase predicha es «filamento» si y solo si $z > 0$, es decir, si $p > 0{,}5$. La binarización solo sirve para decidir qué regiones son críticas; el gradiente llega a la red a través de las probabilidades de los píxeles de esas regiones (Sección 2.6.1).

Topograph actúa, por tanto, sobre las componentes de $X_{0,5}$ y de su complemento: el mismo conjunto de supernivel con el que se elige la época y el que la Sección 4.2 lee en el diagrama.

5.4 Post-proceso

Las instancias se obtienen del mapa de probabilidades p a 512×512. Los cuatro post-procesos del trabajo comparten el mismo esquema: se umbraliza el mapa, $X_t = \{p > t\}$, se toma cada componente 8-conexa de X_t como candidata y se decide cuáles conservar. En la lectura de la Sección 4.2, las candidatas son los puntos del diagrama H_0 de superniveles vivos en t, y cada post-proceso es una regla distinta para decidir cuáles de ellos convertir en instancias.

Para una componente C de X_t, sean $|C|$ su área en píxeles, D_C el conjunto de puntos de $\mathrm{Dgm}_0(p)$ que nacen en un máximo de p situado dentro de C, y

$$\pi(C) = \max_{(b,d)\in D_C} (b - d)$$

la mayor persistencia de esos máximos. El diagrama es el de la filtración de superniveles de p en toda la imagen, no solo por encima de t, de modo que la muerte d puede ser menor que t. La Tabla 5.3 recoge la regla de cada post-proceso.

Post-proceso	Se conserva C si	Fusión	Parámetros y rangos
B1	siempre	no	$t \in [0{,}2,\ 0{,}9]$
B2	$\lvert C\rvert \geq a$	no	$t \in [0{,}2,\ 0{,}9]$, $a \in [0,\ 300]$
E2	$\pi(C) \geq \tau$	sí, con δ	$t \in [0{,}2,\ 0{,}9]$, $\tau \in [0{,}01,\ 0{,}5]$, $\delta \in [0,\ 0{,}3]$
B2+P	$\lvert C\rvert \geq a$ **o** $\pi(C) \geq \tau$	no	$t \in [0{,}2,\ 0{,}9]$, $a \in [0,\ 300]$, $\tau \in [0{,}01,\ 1]$

Tabla 5.3: Regla de cada post-proceso para decidir si se conserva una componente C de X_t. Las áreas son en píxeles a 512×512.

Filtro de área (B1 y B2). Se reescala p a 2048×2048 (interpolación bilineal), se umbraliza y se descartan las componentes de área menor que a, multiplicada por 16 a resolución completa. B1 solo ajusta el umbral ($a = 0$); B2 ajusta el umbral y el área conjuntamente. Es una regla geométrica: solo mira el tamaño de cada componente (Sección 4.2).

Filtro por persistencia (E2). Sustituye el área por la persistencia: se conserva C si contiene un máximo con $b - d \geq \tau$. Esos máximos son los h-máximos de altura τ [25], que se calculan con una reconstrucción morfológica en tiempo casi lineal. Se ha comprobado sobre imágenes sintéticas que la selección coincide con la que da el diagrama calculado con *union-find* y la regla del mayor (Sección 2.3.4). Después, dos componentes conservadas forman una sola instancia si están en la misma componente de $X_{t-\delta}$, es decir, si el collado que las separa está a menos de δ por debajo del umbral (*fusión por collado*). La fusión no añade píxeles: solo cambia qué píxeles forman cada instancia. Como el filtro se aplica antes de la fusión, un trozo poco persistente se elimina aunque esté cerca de otro robusto. La persistencia se mide sobre p, con τ en unidades de probabilidad.

Área o persistencia (B2+P). Combina las dos reglas anteriores, sin fusión: se eliminan las componentes pequeñas y poco persistentes, pero se conservan las pequeñas y robustas. Con τ en el máximo del rango, ninguna componente pequeña cumple la condición de persistencia y B2+P se reduce prácticamente a B2.

En E2 y B2+P, la persistencia y el área se calculan a 512×512, que es la resolución a la que trabaja el modelo, y la decisión se traslada a 2048×2048: cada componente de la máscara a resolución completa toma la instancia de 512×512 con la que más píxeles comparte.

Ajuste. En los cuatro casos, los parámetros se buscan en val A con Optuna [3] (búsqueda bayesiana TPE, 60 intentos, semilla fija), y cada intento se evalúa con la métrica oficial. El post-proceso se aplica a las predicciones ya guardadas de cada ejecución, sin reentrenar.

5.5 Ajuste de hiperparámetros

Las comparaciones de pérdidas usan los mismos hiperparámetros para todas. Puede ocurrir que una pérdida salga peor solo porque esos valores le sientan peor. Para comprobarlo, se ajustan los hiperparámetros de entrenamiento de la baseline y de las dos pérdidas más relevantes para el trabajo: Topograph, que es el método topológico central, y clDice, que apunta a las barbas.

Se usa Optuna con TPE y, para cada modelo, se buscan tres valores: la tasa de aprendizaje en $[10^{-4}, 10^{-3}]$, el *weight decay* en $[10^{-6}, 10^{-3}]$ (ambos en escala logarítmica) y un peso propio de cada pérdida: el de Dice en la baseline ($[0{,}25,\ 0{,}75]$, con BCE el resto hasta 1), α en Topograph ($[0{,}01,\ 0{,}16]$) y el de clDice ($[0{,}10,\ 0{,}40]$, restado del de Dice). El primer intento de cada búsqueda es la configuración de la Sección 5.2. El objetivo es el PQ oficial en A. Los intentos que, a partir de la época 10, van por debajo de la mediana de los anteriores en esa misma época se interrumpen. Cada modelo dispone de 3 horas de cómputo en una GPU NVIDIA GeForce RTX 3090, lo que da entre 27 y 42 intentos por modelo, de los que se completan entre 8 y 15.

5.6 Evaluación

Métrica oficial. Se usa el código del cuaderno oficial de autoevaluación de la competición [2], sin modificarlo. La cifra principal es el PQ global en B a resolución completa (Sección 3.3), con SQ y RQ, y las distribuciones de la rúbrica: IoU, Dice y relaciones 1:n y n:1.

5.6.1 Tipos de error

El PQ cuenta aciertos, falsos positivos y falsos negativos, pero no dice de qué tipo es cada error. Para contarlos se usa la misma relación que las gráficas oficiales de la rúbrica, organizada como un grafo.

Definición 5.1. *Dada una anotación de una imagen, con filamentos $G_1, \dots, G_m$, y las instancias predichas $P_1, \dots, P_k$ para esa imagen, el* grafo de contacto *es el grafo bipartito con un vértice por filamento y uno por instancia, y una arista entre G_i y P_j si comparten al menos un píxel, es decir, si* $\mathrm{IoU}(G_i, P_j) > 0$.

Si la predicción fuera perfecta, el grafo de contacto sería un emparejamiento perfecto: cada filamento tocaría exactamente una instancia y viceversa. Cada tipo de error es una forma de alejarse de esa situación, y se lee en los grados de los vértices (Figura 5.1):

- *partido*: filamento de grado al menos 2, tocado por varias instancias;
- *unido*: instancia de grado al menos 2, que toca varios filamentos;
- *sin predicción*: filamento de grado 0;
- *sin filamento*: instancia de grado 0.

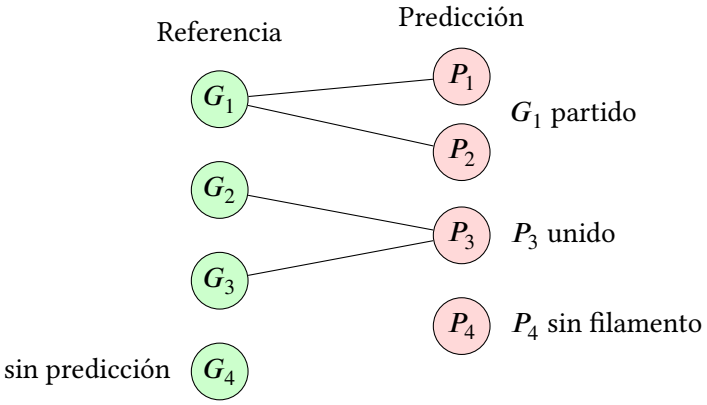


Figura 5.1: Grafo de contacto de una imagen con cuatro filamentos y cuatro instancias predichas. G_1 está partido (grado 2), P_3 une G_2 y G_3 (grado 2), P_4 no toca ningún filamento y G_4 no lo toca ninguna instancia. Ilustración propia.

Los cuatro recuentos se suman sobre todos los pares anotador–imagen de B y se agrupan en dos medidas:

- *Errores de estructura* (P. + U.): filamentos partidos más instancias unidas. Son las discrepancias locales en β_0 de la Sección 4.1: un filamento real representado por varias componentes, o varias por una sola.
- *Errores de presencia* (S. P. + S. F.): filamentos sin predicción más instancias sin filamento. Son componentes que faltan o que sobran.

La separación es útil porque las líneas de mejora apuntan a errores distintos. Una pérdida topológica o la fusión por collado deberían reducir sobre todo los errores de estructura, y un filtro sobre las componentes, los de presencia. El PQ los mezcla: un filamento partido y una mancha espuria penalizan de forma parecida. Además, los recuentos del grafo de contacto no dependen del umbral de IoU $> 0{,}5$ del PQ, así que también registran los errores de las predicciones que tocan un filamento sin llegar a acertarlo. Estas medidas complementan a las oficiales y nunca las sustituyen.

A partir de las detecciones oficiales se calculan también la *precisión*, $\mathrm{TP}/(\mathrm{TP}+\mathrm{FP})$, y la *exhaustividad*, TP/n_B, con $n_B = 869$ el número de filamentos anotados en $\boldsymbol{B}$.

5.6.2 Barbas

El PQ no distingue si un acierto incluye las barbas. Para medirlo se usa la espina que MAGFiLO anota en cada filamento [1] y el esqueleto de la máscara. El esqueleto reduce la máscara a un grafo de curvas de un píxel de grosor con su misma topología: la espina es su camino principal, y las barbas, ramas que salen de él.

Sea w el grosor medio del filamento (área entre longitud de la espina). Las *barbas* son la parte del esqueleto de la máscara anotada que queda fuera de un tubo de radio $1{,}5 \cdot w/2$ alrededor de la espina, sin los trozos de menos de 6 píxeles, que son ruido del esqueleto. La *zona de barbas* es el entorno del filamento, hasta una distancia $2w$, sin ese tubo ni los demás filamentos. Con una tolerancia de 3 píxeles para considerar que dos píxeles coinciden, se definen:

- *cobertura*: fracción del esqueleto de las barbas reales que cubre la predicción;
- *precisión*: fracción del esqueleto de la predicción en la zona de barbas que cae sobre una barba real;
- su F_1;
- *ramas inventadas*: ramas del esqueleto de la predicción en la zona de barbas que no tocan ninguna barba real, por filamento;

- *cobertura de la espina*: fracción de la espina anotada que cubre la predicción.

Todo se mide a 2048×2048, por anotación de $\boldsymbol{B}$. Es una medida propia de este trabajo.

5.6.3 Incertidumbre

***Bootstrap* por días.** $\boldsymbol{B}$ tiene 66 días, y una diferencia de PQ puede deberse a qué días han caído en él. Para estimar esa variabilidad se usa un *bootstrap* pareado por días [12]: se remuestrean con reemplazo los días de $\boldsymbol{B}$ (2.000 veces), se recalcula el PQ global de cada ejecución con los conteos de esos días y se toma el intervalo del 95 % de la diferencia con la referencia. El mismo remuestreo se aplica a todas las ejecuciones, para que la comparación sea pareada. Se remuestrean días, y no pares, porque los pares de un mismo día no son independientes.

Variabilidad entre entrenamientos. El entrenamiento en GPU no es determinista: reentrenar la misma configuración con la misma semilla cambia el PQ en $\boldsymbol{B}$ entre 0,01 y 0,02. Las diferencias menores que eso no se interpretan como mejoras.

5.7 Reproducibilidad

Cada ejecución queda identificada por la fecha, la configuración y el *commit* del código, y guarda su configuración completa, la época elegida, las predicciones y los *logits* de validación. Una tabla única registra una fila por ejecución con sus métricas en $\boldsymbol{A}$ y $\boldsymbol{B}$, y otra, los recuentos del grafo de contacto por par anotador–imagen. Los resultados del Capítulo 6 salen de esas tablas. El Apéndice A describe los módulos y cómo reproducir cada experimento.

6 Experimentos y resultados

Este capítulo busca responder a la pregunta que guía el trabajo, qué aporta la topología a la segmentación de filamentos. En primer lugar, vemos qué errores comete el modelo de referencia y cuántos de ellos se corrigen de forma sencilla, descartando las componentes pequeñas (Sección 6.1). A partir de ahí, empleamos la topología en dos momentos, durante el entrenamiento, con Topograph (Sección 6.2), y después de él, con un post-proceso basado en persistencia (Sección 6.3). Cerramos con tres experimentos adicionales, sobre las barbas, el ajuste de hiperparámetros y el test de la competición (Sección 6.4).

El análisis se centra en la comparación entre la baseline y Topograph, que es la que mejor muestra el efecto de una pérdida topológica, y los resultados completos del resto de pérdidas se recogen en el Apéndice B. Todas las decisiones, es decir, la época elegida de cada modelo, los hiperparámetros y los parámetros de los post-procesos (umbral, área mínima y persistencia mínima), se toman en val A, y las cifras que se presentan corresponden a val B (Capítulo 5). De este modo, los resultados no están sesgados por la propia selección. Conviene tener presente, además, que entrenar dos veces la misma configuración modifica el PQ entre 0,01 y 0,02, y que cambiar la semilla puede modificarlo más, por lo que las diferencias de ese tamaño no se interpretan como mejoras.

6.1 Punto de partida

Antes de emplear la topología conviene ver hasta dónde llega el post-proceso de área, B2 (Sección 5.4), que fija un umbral y descarta las componentes pequeñas. La Tabla 6.1 muestra que casi toda su mejora se debe al área mínima. Mover el umbral apenas cambia el resultado, pero en cuanto se eliminan las componentes pequeñas

el PQ de la baseline pasa de 0,311 a 0,373. Lo que desaparece son sobre todo falsos positivos, que se reducen a menos de la mitad, mientras que los aciertos que se pierden por el camino son pocos. Por eso mejora la detección de filamentos (RQ) y no la calidad con que se delimita cada uno (SQ). Con este filtro, la baseline supera ya el valor de 0,35 que los organizadores dan como referencia (Sección 3.3).

Post-proceso	t	a	PQ	SQ	RQ	TP	FP / FN
Sin post-proceso	0,50	0	0,311	0,638	0,488	495	665 / 374
B1 (umbral)	0,66	0	0,313	0,646	0,484	494	678 / 375
B2 (umbral y área)	0,66	29	**0,373**	0,650	0,574	458	269 / 411

Tabla 6.1: Post-proceso por umbral (B1) y por umbral y área (B2) de la baseline (semilla 42) en val $\boldsymbol{B}$, ajustado con Optuna en val $\boldsymbol{A}$. t es el umbral y a el área mínima en píxeles a 512×512. La comparación con la búsqueda en rejilla está en la Tabla B.1.

Que un criterio tan sencillo funcione tan bien dice mucho del tipo de errores que comete el modelo. Si se clasifican con la relación de contacto de la rúbrica (Sección 5.6), los errores de presencia, es decir, filamentos sin predicción y predicciones sin filamento, son más de cuatro veces más numerosos que los de estructura, los filamentos partidos o unidos (Figura 6.1). El problema principal no es, por tanto, cómo se conectan las predicciones, sino si aparecen donde deben. En términos del diagrama $\boldsymbol{H}_0$ (Sección 4.2), sobran o faltan componentes, y el filtro de área elimina muchas de las que sobran porque suelen ser pequeñas. Es, con todo, una solución poco selectiva, ya que descarta cualquier componente pequeña sin comprobar si corresponde a un filamento real, y con ellas se pierden también filamentos pequeños que estaban bien detectados.

Esta diferencia entre tipos de error es también la razón por la que el capítulo no se limita al PQ. La métrica reúne en un solo número errores de naturaleza muy distinta, y penaliza de forma parecida no detectar un filamento, predecir uno donde no lo hay o partir uno en dos. Por eso, en lo que sigue, cada método se juzga también por los errores que corrige, y B2 se toma como post-proceso de referencia, ya que es el resultado que cualquier propuesta debe mejorar.

6.2 La topología en el entrenamiento

Para medir el efecto de las pérdidas topológicas comparamos las cinco pérdidas de la Tabla 5.2, cada una con y sin Topograph, con las dos semillas de la baseline y

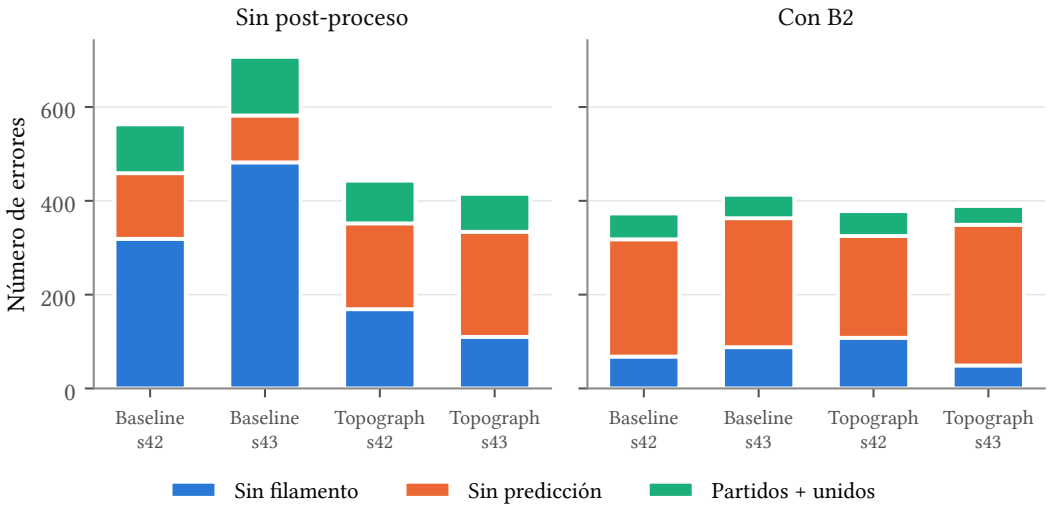


Figura 6.1: Tipos de error en val ***B*** de la baseline y de Topograph, con las dos semillas, sin post-proceso (izquierda) y con B2 (derecha). Las predicciones sin filamento y los filamentos sin predicción son errores de presencia; los partidos y unidos, de estructura. Los valores están en la Tabla B.3.

de Topograph descritas en la Sección 5.2. Como se anticipó en la Sección 2.5, la que combina BCE y clDice sin un término de solapamiento colapsa, con Topograph y sin él, y se deja fuera del análisis.

6.2.1 Predicciones más fiables

El efecto más claro de Topograph no está en cuántos filamentos encuentra, sino en que lo que encuentra suele ser un filamento de verdad. Sin post-proceso, todas las variantes con Topograph son más precisas que cualquiera de las variantes sin él (Tabla B.4). En la Figura 6.2 (izquierda), que sitúa cada modelo según su exhaustividad y su precisión, todos los puntos naranjas, los de Topograph, quedan por encima de todos los azules. Esta ganancia se debe a que el modelo predice muchas menos componentes donde no hay filamento, entre un 38 y un 63 % menos según la pérdida a la que se añada Topograph (Tabla B.3). A cambio, la exhaustividad baja un poco, porque el modelo deja de predecir algunos filamentos dudosos.

Es el comportamiento que cabe esperar de cómo está construida la pérdida (Sección 2.6.1). Una componente predicha que no toca ningún filamento cambia el número

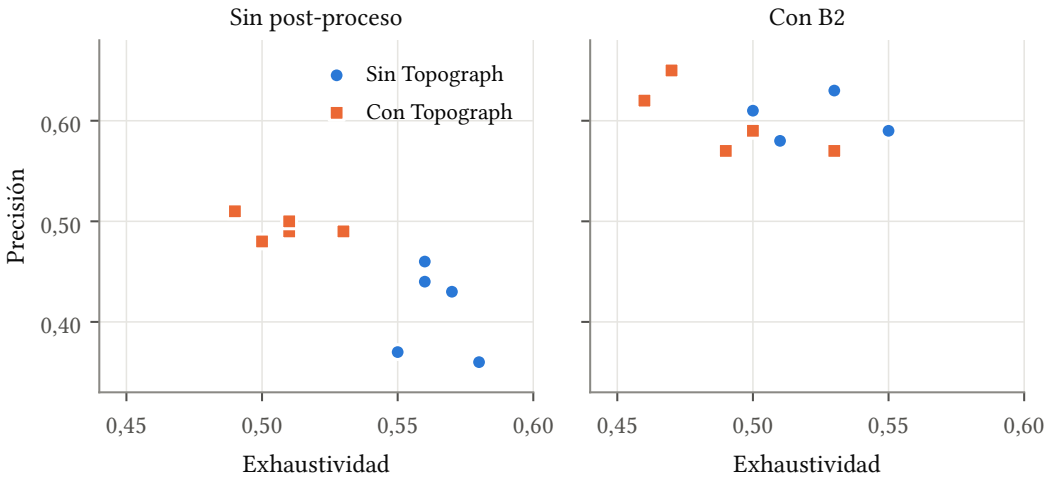


Figura 6.2: Precisión frente a exhaustividad en val ***B***, sin post-proceso (izquierda) y con B2 (derecha). Cada punto es un modelo (las ocho pérdidas, con las dos semillas de la baseline y de Topograph); en naranja, las variantes con Topograph. Los valores están en la Tabla B.4.

de componentes de la predicción, así que es una región crítica y Topograph la penaliza. El modelo aprende, por tanto, a predecir una componente solo cuando la imagen la respalda con claridad. En un problema en el que dos expertos coinciden apenas en un PQ de 0,34 (Sección 4.1.4), contar con un modelo cuyas detecciones caen sobre un filamento real en más del 80 % de los casos (Tabla B.4) tiene un valor que el PQ no recoge del todo.

La mejora llega también al PQ, aunque de forma más modesta. Sin post-proceso, Topograph obtiene el mejor resultado tanto en val *A* como en val ***B*** (Tabla B.2), y supera a la baseline en los tres entrenamientos en que se han comparado, las dos semillas y el reentrenamiento del ajuste de hiperparámetros (Tabla B.10). Las demás variantes topológicas también quedan por encima de la baseline, mientras que IoU, que no tiene sesgo topológico, queda por debajo.

La estructura también mejora. Las predicciones que unen varios filamentos son escasas en todos los modelos, entre 12 y 18 (Tabla B.3), así que la diferencia la marcan los filamentos partidos. Si se compara cada pérdida con su versión con clDice, por ejemplo la baseline con clDice o IoU con IoU+clDice, los partidos bajan en los cuatro casos. Al añadir Topograph bajan en tres de los cuatro, y la excepción es IoU+clDice, que pasa de 57 a 63.

6.2.2 Topograph y el filtro de área

El análisis anterior se hizo sin post-proceso, pero en la práctica las predicciones se filtran con B2. Como este filtro también elimina predicciones sin filamento, aunque solo atendiendo a su tamaño, es posible que la ventaja de Topograph se diluya al aplicarlo. Con B2 la precisión de todos los modelos sube, y en la Figura 6.2 (derecha) los puntos naranjas y azules ya no aparecen separados. La Tabla 6.2 y el panel derecho de la Figura 6.1 permiten comprobar si Topograph sigue aportando algo cuando la baseline ya ha eliminado sus componentes pequeñas.

Pérdida	Post	PQ	P. + U.	Sin fil.	FP	Prec.
Baseline (s42)	sin	0,311	104	319	665	0,43
Topograph (s42)	sin	0,327	91	169	481	0,49
Baseline (s43)	sin	0,287	125	482	899	0,36
Topograph (s43)	sin	0,322	81	110	402	0,51
Baseline (s42)	B2	**0,373**	55	68	269	0,63
Topograph (s42)	B2	0,354	53	108	342	0,57
Baseline (s43)	B2	0,357	50	88	279	0,61
Topograph (s43)	B2	0,355	**40**	**49**	**220**	**0,65**

Tabla 6.2: Baseline y Topograph en val ***B***, con las dos semillas, sin post-proceso y con B2. P. + U.: filamentos partidos más unidos (errores de estructura). Sin fil.: predicciones que no tocan ningún filamento. FP: falsos positivos de la métrica oficial. Prec.: precisión. En negrita, el mejor valor de cada columna. Las diez pérdidas están en las Tablas B.3 y B.4.

Con la semilla 43, Topograph con B2 es el modelo con menos errores de estructura, menos predicciones sin filamento y mayor precisión de toda la comparación de pérdidas. Es, por tanto, el modelo cuyas predicciones corresponden con más frecuencia a un filamento real, algo que tiene especial valor cuando los propios expertos discrepan tanto.

Esta ventaja, sin embargo, no se traduce en el PQ, y la lectura topológica ayuda a entender por qué. Una predicción sin filamento es una componente de H_0 que no tiene correspondencia en la referencia. Topograph enseña al modelo a no generarla, y B2 la elimina después por ser pequeña, de modo que ambos corrigen el mismo error en momentos distintos. Como el filtro ya limpia buena parte de los errores de la baseline, a Topograph le queda poco margen en la métrica, y el PQ de los dos modelos apenas se

diferencia. Lo que conserva Topograph es una ventaja en la estructura y en la fiabilidad de sus predicciones.

Este resultado depende, eso sí, de la semilla. Con la 43, la ventaja de Topograph con B2 es clara, pero con la 42 solo mejora ligeramente a la baseline en errores de estructura, y queda por detrás en predicciones sin filamento y en precisión. Sin post-proceso, en cambio, la mayor fiabilidad de Topograph se repite con las dos semillas, y es por tanto el resultado más sólido de esta sección.

La semilla fija la inicialización de la red y el orden en que se le presentan los datos durante el entrenamiento. Con todo lo demás igual, pasar de la semilla 42 a la 43 cambia la comparación entre Topograph y la baseline con B2, así que hay que ser prudente con las diferencias que salen de una sola ejecución. Para medir la incertidumbre de cada comparación se usa un *bootstrap* pareado por días (Capítulo 5). Este método simula qué habría pasado si val $\boldsymbol{B}$ estuviera formada por otros días. Una diferencia entre dos modelos se considera significativa si su intervalo del 95 % no contiene el 0, es decir, si en casi todos los remuestreos uno de los dos modelos queda por encima del otro. Pero los modelos que compara son siempre los mismos, ya entrenados, así que no tiene en cuenta que, al volver a entrenarlos, saldrían algo distintos. Esto se ve al comparar la baseline consigo misma. Las semillas 42 y 43 corresponden a la misma configuración, y aun así el *bootstrap* da la de la semilla 43 como significativamente peor, con 0,024 menos de PQ sin post-proceso (Sección B.3). Una diferencia «significativa» puede deberse, por tanto, a que una ejecución salió especialmente bien o mal, y por eso el trabajo se fija sobre todo en lo que se repite entre semillas. Topograph mejora a la baseline sin post-proceso con ambas, lo que apunta a una mejora real. Con B2, en cambio, las diferencias son del mismo orden que la que separa a las dos semillas de la baseline.

Al comparar los dos paneles de la Figura 6.1 se ve el coste de B2 que se adelantaba en la Sección 6.1. Al eliminar las componentes pequeñas desaparecen también filamentos reales, y con el filtro los filamentos sin predicción pasan a ser el error más frecuente en todos los modelos. De ahí surge la pregunta de la siguiente sección, si un criterio topológico podría eliminar las predicciones espurias sin perder esos filamentos.

6.3 La topología en el post-proceso

Siguiendo la lectura topológica de la Sección 4.2, sustituimos el tamaño por la persistencia en H_0 como criterio para decidir qué componentes conservar. La hipótesis H2 (Sección 4.3) es que un filamento pequeño pero bien definido es más persistente que una mancha espuria, de modo que este criterio eliminaría las espurias sin perder los filamentos que descarta B2. Para comprobarlo empleamos los dos post-procesos de la Sección 5.4, E2 y B2+P. La Tabla 6.3 los compara con B2 en la baseline y en Topograph, y la Sección B.4 recoge los once modelos en los que se aplicaron. Como las diferencias de PQ son pequeñas, la comparación se centra en qué errores corrige cada uno.

Modelo	Post	PQ	P. + U.	Sin pred.	Sin fil.	Prec.
Baseline	sin	0,303	112	143	318	0,41
	B2	**0,368**	49	255	72	0,63
	E2	0,314	91	142	279	0,44
	B2+P	**0,368**	36	213	116	0,60
Topograph	sin	0,330	88	189	158	0,50
	B2	**0,362**	52	237	89	0,61
	E2	0,339	76	191	139	0,52
	B2+P	**0,362**	**34**	235	93	0,61

Tabla 6.3: Post-procesos en val B sobre la baseline y Topograph, entrenados con los hiperparámetros del mejor intento de su ajuste (Sección 6.4.2). En negrita, el mejor PQ de cada modelo y el menor número de partidos y unidos. P. + U.: filamentos partidos más unidos (errores de estructura). Sin pred. y Sin fil.: errores de presencia. Prec.: precisión. Los once modelos están en las Tablas B.7 y B.8.

E2 cumple la primera parte de la hipótesis. Al decidir por persistencia y no por tamaño, conserva los filamentos pequeños que B2 descarta, y en casi todos los modelos no pierde ninguno de los que el modelo había detectado. Con la baseline llega incluso a la mayor exhaustividad de todo el trabajo (Tabla B.8). Corrige además parte de la fragmentación, porque cuenta como una sola instancia los trozos de un filamento separados por un hueco pequeño y descarta los fragmentos poco persistentes. E2 es, por tanto, un post-proceso conservador, que respeta la estructura de lo que predice el modelo en lugar de recortarla.

Lo que E2 no consigue es eliminar tantas predicciones espurias como el filtro de área. Con la baseline apenas las reduce, y el ajuste elige una persistencia mínima casi

nula, porque un valor mayor eliminaría también aciertos. La razón es que la baseline se equivoca con mucha seguridad. Una mancha aislada sobre un fondo cercano a 0 tiene una persistencia casi igual a la altura de su pico, y esos picos son tan altos como los de los filamentos reales (Sección 4.1). La persistencia termina midiendo lo mismo que la confianza del modelo, y lo que distingue a estas espurias es su tamaño, que E2 no tiene en cuenta. Con Topograph, cuyas espurias son menos persistentes, E2 elimina bastantes más. La hipótesis H2 se cumple, por tanto, solo en parte. La persistencia es un buen criterio para conservar la estructura, pero no basta por sí sola para separar las espurias y necesita el apoyo del área, que es lo que motiva B2+P.

B2+P parte de esa idea y combina los dos criterios. Filtra por tamaño de forma más estricta que B2 y solo rescata las componentes pequeñas con una persistencia casi máxima, de modo que la persistencia actúa aquí como un criterio de confianza adicional. El resultado depende de cómo se entrenó el modelo. En los cinco modelos entrenados con Topograph, B2+P iguala o mejora ligeramente el PQ de B2, con menos errores de estructura y mayor precisión. En los seis entrenados sin él, el PQ queda igual o por debajo y la precisión baja siempre, porque sus espurias muy seguras también superan el criterio de persistencia (Sección B.4). Las dos formas de emplear la topología se complementan, por tanto. Topograph hace que las espurias sean menos persistentes, y eso es lo que permite al post-proceso por persistencia distinguirlas. Esta combinación es la más favorable del trabajo desde el punto de vista topológico, con la cautela de que la baseline queda cerca y de que cada modelo procede de un único entrenamiento.

6.4 Experimentos adicionales

6.4.1 Barbas

Las barbas, que motivaron el uso de clDice, siguen siendo la parte del filamento que peor se recupera, y ninguna técnica topológica mejora su detección. Como la anotación reducida a 512×512 las conserva casi enteras, la mejora tendrá que venir de detectarlas mejor, una línea que queda abierta (Sección B.5).

6.4.2 Ajuste de hiperparámetros

Al ajustar los hiperparámetros de la baseline, Topograph y clDice, las dos pérdidas topológicas se acercan a la baseline, pero la comparación entre los tres modelos no cambia. En las pruebas realizadas, por tanto, la configuración estudiada no parece condicionar los resultados (Sección B.6).

6.4.3 Test de la competición

En el test de la competición todos los modelos bajan entre 0,06 y 0,10 de PQ respecto a val ***B***, una caída común a todas las configuraciones cuya causa no se ha podido determinar. Entre los post-procesos se mantiene el orden de la validación, con B2+P igual o por encima de B2 (Sección B.7).

En conjunto, los resultados muestran que la topología aporta más en la calidad de las predicciones que en la métrica de la competición. Topograph produce detecciones más fiables y menos fragmentadas, la persistencia conserva la estructura que el filtro de área recorta, y ambas se complementan cuando se combinan. El Capítulo 7 recoge estas conclusiones y sus limitaciones.

7 Conclusiones y trabajo futuro

7.1 Conclusiones

El trabajo se preguntaba qué aporta la topología a la segmentación de los filamentos solares. La respuesta se resume en tres conclusiones, que corresponden a los tres usos que se le han dado: describir los errores, corregirlos durante el entrenamiento y corregirlos después, en el post-proceso.

La topología como lenguaje de los errores. La homología persistente describe con precisión los errores que más pesan en este problema. Un filamento partido, dos filamentos fusionados o una componente espuria son cambios en el número de componentes conexas, β_0. El post-proceso habitual tiene además una lectura exacta en el diagrama H_0, porque las instancias que deja un umbral son los puntos del diagrama nacidos por encima de él y aún no muertos (Proposición 4.1). En ese lenguaje, el filtro de área decide qué puntos conservar mirando solo su tamaño. Con la baseline funciona bien, porque la mayoría de sus errores son componentes pequeñas sin filamento, y sube el PQ de 0,311 a 0,373, mientras que ajustar solo el umbral no lo mejora. Se confirma así la hipótesis H1, según la cual los errores dominantes son componentes que sobran o que faltan. Pero el filtro de área también elimina filamentos reales pequeños, y eso motivó buscar un criterio topológico. Este punto de vista ha permitido, por último, separar los errores de estructura (partidos y unidos) de los de presencia (filamentos perdidos y predicciones espurias), y medir cada método por los errores a los que apunta y no solo por el PQ.

Pérdidas topológicas. La Tabla 7.1 resume la comparación de pérdidas, sin las dos variantes de clDice sin Dice, que colapsan.

	Sin post-proceso				B2			
Pérdida	PQ	P. + U.	S. P. + S. F.	Prec.	PQ	P. + U.	S. P. + S. F.	Prec.
Baseline (s42)	0,311	104	459	0,43	**0,373**	55	318	0,63
Baseline (s43)	0,287	125	582	0,36	0,357	50	363	0,61
IoU	0,285	136	499	0,37	0,351	58	342	0,58
clDice	0,313	90	400	0,44	0,354	54	332	0,57
IoU+clDice	0,322	**72**	385	0,46	0,363	49	**311**	0,59
Topograph (s42)	**0,327**	91	352	0,49	0,354	53	325	0,57
Topograph (s43)	0,322	81	**334**	**0,51**	0,355	**40**	349	**0,65**
IoU+Topo	0,315	92	341	0,48	0,346	49	355	0,62
clDice+Topo	0,317	80	339	0,49	0,348	51	322	0,59
IoU+clDice+Topo	0,318	81	358	0,50	0,336	58	330	0,57

Tabla 7.1: Comparación final de las pérdidas en val ***B***, sin post-proceso y con B2. P. + U.: filamentos partidos más predicciones que unen varios filamentos (errores de estructura). S. P. + S. F.: filamentos sin predicción más predicciones sin filamento (errores de presencia). Prec.: aciertos entre predicciones. En negrita, el mejor valor de cada columna. Las cifras completas están en el Apéndice B.

Sin post-proceso, las pérdidas topológicas mejoran a las de solapamiento. Todos los modelos con Topograph tienen más precisión y menos errores de presencia que cualquiera sin él, y tanto clDice como Topograph reducen los errores de estructura, lo que confirma la hipótesis H3. Con el filtro de área, en cambio, el PQ de las distintas pérdidas apenas se diferencia, porque Topograph y el filtro corrigen el mismo error, las predicciones espurias. La ventaja de las pérdidas topológicas está, por tanto, en la estructura y la fiabilidad de las predicciones más que en la métrica. La excepción son las barbas, que ninguna pérdida mejora, de modo que la hipótesis H4 no se cumple.

Post-proceso por persistencia. El filtro por persistencia conserva los filamentos y reduce la fragmentación, pero no elimina las predicciones espurias mejor que el área, porque en la baseline su persistencia es casi igual a su confianza, que es tan alta como la de los aciertos. La hipótesis H2 se cumple, por tanto, solo en parte, y la persistencia funciona mejor como complemento del área. Combinadas (B2+P) en modelos entrenados con Topograph, dan menos errores de estructura y más precisión que B2 sin perder PQ, mientras que sin Topograph la precisión baja (Sección B.4). Las dos formas de emplear la topología se complementan, y su combinación es la más favorable del trabajo.

Estas conclusiones se apoyan en lo que se repite entre semillas y no en diferencias aisladas, porque la variación entre entrenamientos, de hasta 0,024 en PQ, es del mismo orden que las diferencias entre pérdidas. Por eso todas las decisiones se tomaron en una mitad de la validación y los resultados se reportan en la otra.

En conjunto, la topología no ha dado una mejora clara en la métrica de la competición, que un filtro de área ya resuelve en buena parte, pero sí ha aportado lo que el tamaño no ofrece. Ha dado una forma precisa de entender y clasificar los errores, una pérdida que produce predicciones más fiables y con menos fragmentación, y un post-proceso que conserva la estructura de los filamentos.

7.2 Limitaciones

- *Pocas ejecuciones por pérdida.* Solo la baseline y Topograph se han entrenado con dos semillas. Dada la variación observada entre semillas, las diferencias pequeñas entre pérdidas no pueden confirmarse.
- *Tamaño de la validación.* val ***B*** contiene 66 días, lo que da intervalos de confianza de una anchura comparable a las diferencias que se quieren medir.
- *Resolución.* El modelo trabaja a 512×512, un cuarto de la resolución original en cada eje. La anotación reducida a esa resolución conserva el 99,7 % del esqueleto de las barbas, así que la salida no las limita. Sin embargo, en la imagen de entrada una barba mide entre 1 y 3 píxeles, y no se ha comprobado si el modelo detectaría más barbas trabajando a mayor resolución.
- *Ajuste limitado.* La comparación completa de pérdidas usa una configuración común, sin aumento de datos. El ajuste de la Sección 6.4.2 indica que esa configuración se adaptaba mejor a la baseline, pero solo cubre tres modelos, con 3 horas de búsqueda por modelo.
- *Generalización al test.* El PQ en el *leaderboard* público queda entre 0,06 y 0,10 por debajo del de val ***B***, y la causa no se ha podido determinar.
- *Una sola arquitectura*, la U-Net con ResNet-34.

7.3 Trabajo futuro

- **Filtraciones que vean el tamaño y la forma.** E2 muestra que la persistencia conserva la estructura, pero no separa las predicciones espurias muy seguras,

porque en H_0 de la probabilidad se reduce casi a la confianza del pico. Queda por explorar filtraciones que tengan en cuenta también el tamaño o la forma de las componentes, y un ajuste de B2+P con más intentos.

- **Estrategias de etiquetas.** Para abordar el desacuerdo entre anotadores, comparar el entrenamiento con cada anotación como un ejemplo independiente, que es la opción de la baseline, con el entrenamiento con la media de las anotaciones como etiqueta blanda y con los filamentos que marca la mayoría. La evaluación seguiría haciéndose contra cada anotación original.
- **Más semillas por pérdida**, para separar las diferencias reales del ruido del entrenamiento.
- **Barbas: resolución y pérdidas específicas.** Comprobar si entrenar a mayor resolución, por ejemplo por parches, mejora la detección de las barbas, y probar pérdidas que den más peso a la zona de las barbas, ya que clDice optimiza sobre todo la espina.
- **Otras pérdidas topológicas**, como Betti matching [27], que garantiza la correspondencia espacial de las estructuras a un mayor coste computacional.

A | Código y reproducibilidad

Todo el código del trabajo es público en `https://github.com/AgustinG-git/tfm-filamentos`. La versión que corresponde a esta memoria está marcada con la etiqueta `v1.0-deposito`. Este apéndice describe cómo está organizado y cómo se reproduce cada resultado.

A.1 Organización

El código se divide en una biblioteca, `filseg`, con las piezas del protocolo, y una serie de *scripts* que las combinan para cada experimento (Tablas A.1 y A.2). Las configuraciones de cada experimento son ficheros YAML en `configs/`, que heredan de la baseline y cambian solo la pieza que se estudia.

Topograph se usa a través de la implementación oficial de sus autores [21], con su extensión compilada en C++. El repositorio incluye además pruebas automáticas (`tests/`) que comprueban, entre otras cosas, que la evaluación propia coincide con la oficial y que la partición no comparte días entre subconjuntos.

A.2 Reproducir un resultado

Cada ejecución lee los datos de la carpeta indicada en `FILSEG_DATA` y escribe en `FILSEG_OUT`. Por ejemplo, la baseline y su post-proceso B2:

```
python scripts/entrenar.py configs/base.yaml
python scripts/postproceso.py --filtro "_base_"
```

Módulo	Contenido
`contract.py`	Decisiones congeladas comunes a todas las ejecuciones (partición, resoluciones, criterio de selección, ficheros de salida). No se modifica.
`split.py`	Partición entrenamiento / val A / val B agrupada por fecha, generada una sola vez.
`gt.py`	Referencia de evaluación en el formato oficial, a partir del JSON de MAGFiLO.
`data.py`	Carga de imágenes a 512×512 y etiquetas de entrenamiento.
`model.py`	U-Net con codificador ResNet-34 [17].
`losses.py`	Las pérdidas de la Tabla 5.2: BCE, Dice, IoU, clDice y Topograph, con su calentamiento.
`train.py`	Una ejecución completa: entrenamiento, selección de la época en val A, evaluación y registro.
`postproc.py`	Post-procesos: umbral y componentes conexas con filtro de área (B1, B2) filtro por persistencia (E2) y su combinación con el área (B2+P).
`postrun.py`	Ajuste en val A de un post-proceso sobre una ejecución ya entrenada, sin reentrenar.
`official_metric.py`	Copia literal del cuaderno oficial de autoevaluación de la competición [2].
`metrics.py`	Evaluación con la métrica oficial y comprobaciones previas (formato, solapes).
`compare.py`	Conteos por anotación, relaciones 1:n y n:1 y *bootstrap* pareado por días.
`runs.py`	Identificadores, salidas de cada ejecución y tabla de registro.

Tabla A.1: Módulos de la biblioteca `filseg`.

Cada ejecución crea una carpeta `runs/<run_id>`, donde el identificador combina la fecha, la configuración y el *commit* del código, con la configuración completa, la época elegida, las predicciones y los *logits* de validación y el envío para la competición. Además añade una fila a `registro.csv` con sus métricas en val A y val B, y sus conteos a `conteos.csv`. Las tablas del Capítulo 6 salen de esos dos ficheros, que están en el repositorio. Como el entrenamiento en GPU no es determinista, repetir una ejecución reproduce sus cifras con una diferencia del orden de 0,01–0,02 en PQ (Sección 5.6).

Script	Uso
`make_split.py`	Genera la partición (una sola vez).
`entrenar.py`	Lanza una ejecución a partir de una configuración.
`cola.sh`	Encadena varias ejecuciones en la misma GPU.
`postproceso.py`	Aplica B1 y B2 a las ejecuciones entrenadas (Sección 6.1).
`e2.py`	Aplica los post-procesos por persistencia (E2 y B2+P).
`ajuste_hp.py`	Ajuste de hiperparámetros con Optuna (Sección 6.4.2).
`resultados.py`	*Bootstrap* y relaciones del Capítulo 6.
`barbas.py`	Medida de barbas y techo a 512×512 (Sección 6.4.1).
`medir_topograph.py`	Escala del término de Topograph, para fijar α.
`figura_magfilo.py`	Figura 3.2.

Tabla A.2: *Scripts* de los experimentos.

A.3 Post-proceso por persistencia

Como ejemplo de cómo se traduce la teoría del Capítulo 2 a código, este es el núcleo del post-proceso por persistencia (comentarios simplificados). Con `area_min` se obtiene la variante B2+P; sin él, E2. El filtro por persistencia se apoya en los h-máximos: los máximos regionales de altura al menos τ son exactamente los puntos del diagrama H_0 de superniveles con persistencia $b - d \geq \tau$. Se ha comprobado, sobre imágenes sintéticas, que la selección coincide con la que se obtiene calculando el diagrama con *union-find* y la regla del mayor (Sección 2.3.4).

```
def persistencia_512(prob, umbral, tau, delta, area_min=None):
    # X_t = {prob > umbral}, componentes 8-conexas
    xt = (prob > umbral).astype(np.uint8)
    n_t, lt = cv2.connectedComponents(xt, connectivity=8)
    # h-maximos: maximos con persistencia b - d >= tau
    hmax = h_maxima(prob, tau, footprint=np.ones((3, 3))) > 0
    keep = np.unique(lt[hmax & (xt > 0)])
    if area_min is not None:     # B2+P: area 0 persistencia
        areas = np.bincount(lt.ravel())
        keep = np.union1d(keep, np.flatnonzero(areas >= area_min))
    vivo = np.isin(lt, keep[keep > 0])
    # fusion por collado: unidas en X_{t - delta} -> una instancia
    _, ld = cv2.connectedComponents(
        (prob > umbral - delta).astype(np.uint8), connectivity=8)
```

```
    lab = np.where(vivo, ld, 0)
    return relabel(lab)          # etiquetas 1..n consecutivas
```

B | Resultados complementarios

Este apéndice recoge las tablas completas de los experimentos del Capítulo 6, con todas las pérdidas, post-procesos y medidas. Todas las cifras son de val *B* salvo que se indique lo contrario.

B.1 Post-proceso de umbral y área

La Tabla B.1 compara la búsqueda en rejilla y con Optuna de los dos post-procesos sencillos, B1 y B2, sobre la baseline (semilla 42). Ambas búsquedas llegan a valores parecidos, lo que indica que la rejilla ya cubría la zona de buenos valores; en el trabajo se usa Optuna. Al subir el umbral sin filtro de área, los falsos positivos aumentan ligeramente, posiblemente porque algunas componentes se dividen.

Post-proceso	t	a	PQ	SQ	RQ	TP	FP / FN
Sin post-proceso	0,50	0	0,311	0,638	0,488	495	665 / 374
B1 (rejilla)	0,65	0	0,314	0,647	0,485	494	674 / 375
B1 (Optuna)	0,66	0	0,313	0,646	0,484	494	678 / 375
B2 (rejilla)	0,65	25	**0,375**	0,649	0,577	473	297 / 396
B2 (Optuna)	0,66	29	0,373	0,650	0,574	458	269 / 411

Tabla B.1: Post-proceso de la baseline (semilla 42) en val *B*. t es el umbral y a el área mínima en píxeles a 512×512, ambos ajustados en val *A*.

B.2 Comparación de pérdidas

La Tabla B.2 da el PQ de las diez pérdidas, en val *A* y val *B*, sin post-proceso y con B2. La combinación de BCE y clDice sin Dice colapsa. El mejor modelo en *A* es el de la primera época (la sexta con Topograph) y su PQ no llega a 0,05 ni con post-proceso. Las Tablas B.3 y B.4 dan los tipos de error y la fiabilidad de las detecciones. De ellas salen las Figuras 6.2 y 6.1.

Dos observaciones complementan las del capítulo. En partidos y unidos, clDice es tan eficaz como Topograph, lo que concuerda con que premia la continuidad de las estructuras alargadas, mientras que IoU, sin sesgo topológico, llega a 123 filamentos partidos. Con B2, los filamentos sin predicción suben en todos los modelos, hasta 201–301, y IoU+Topograph es, tras Topograph (s43), el modelo con menos predicciones sin filamento (54).

		Sin post-proceso		B2 (Optuna)	
Pérdida	Época	PQ *A*	PQ *B*	PQ *A*	PQ *B*
Baseline (s42)	8	0,297	0,311	**0,364**	**0,373**
Baseline (s43)	8	0,276	0,287	0,348	0,357
IoU	15	0,279	0,285	0,351	0,351
clDice	13	0,307	0,313	0,351	0,354
IoU+clDice	14	0,308	0,322	0,345	0,363
clDice sin Dice	1	0,012	0,009	0,062	0,036
Topograph (s42)	17	**0,322**	**0,327**	0,354	0,354
Topograph (s43)	12	0,298	0,322	0,336	0,355
IoU+Topo	16	0,315	0,315	0,346	0,346
clDice+Topo	18	0,307	0,317	0,344	0,348
IoU+clDice+Topo	18	0,297	0,318	0,333	0,336
clDice sin Dice+Topo	6	0,025	0,014	0,080	0,045

Tabla B.2: PQ de cada pérdida en val *A* y val *B*, sin post-proceso (umbral 0,5, sin filtro de área) y con B2 ajustado en val *A* para cada ejecución. La «Época» es la elegida en val *A* y la semilla se fija en 42 salvo que se indique.

Pérdida	Partidos	Unidos	P. + U.	Sin pred.	Sin fil.	S. P. + S. F.
Sin post-proceso						
Baseline (s42)	92	**12**	104	140	319	459
Baseline (s43)	111	14	125	**100**	482	582
IoU	123	13	136	119	380	499
clDice	73	17	90	122	278	400
IoU+clDice	**57**	15	**72**	124	261	385
Topograph (s42)	78	13	91	183	169	352
Topograph (s43)	68	13	81	224	**110**	**334**
IoU+Topo	79	13	92	199	142	341
clDice+Topo	65	15	80	180	159	339
IoU+clDice+Topo	63	18	81	197	161	358
B2 (Optuna)						
Baseline (s42)	43	**12**	55	250	68	318
Baseline (s43)	37	13	50	275	88	363
IoU	45	13	58	247	95	342
clDice	39	15	54	213	119	332
IoU+clDice	34	15	49	**201**	110	**311**
Topograph (s42)	41	**12**	53	217	108	325
Topograph (s43)	**26**	14	**40**	300	**49**	349
IoU+Topo	36	13	49	301	54	355
clDice+Topo	37	14	51	240	82	322
IoU+clDice+Topo	43	15	58	248	82	330

Tabla B.3: Tipos de error en val ***B***, sumados sobre todos los pares anotador–imagen. *Partidos*: filamentos de referencia tocados por dos o más predicciones. *Unidos*: predicciones que tocan dos o más filamentos. *Sin pred.*: filamentos que ninguna predicción toca. *Sin fil.*: predicciones que no tocan ningún filamento. «Tocar» significa solaparse en al menos un píxel (IoU > 0), como en la definición oficial. P. + U. y S. P. + S. F. son las sumas que miden los errores de estructura y de presencia (Sección 5.6). En negrita, el menor valor de cada columna dentro de cada bloque.

	Sin post-proceso			B2 (Optuna)		
Pérdida	Prec.	Exh.	Sin fil. (%)	Prec.	Exh.	Sin fil. (%)
Baseline (s42)	0,43	0,57	27,5	0,63	0,53	9,4
Baseline (s43)	0,36	0,58	34,4	0,61	0,50	12,4
IoU	0,37	0,55	29,3	0,58	0,51	12,5
clDice	0,44	0,56	25,2	0,57	0,53	14,7
IoU+clDice	0,46	0,56	24,6	0,59	0,55	13,7
Topograph (s42)	**0,49**	0,53	**18,0**	0,57	0,53	13,5
Topograph (s43)	**0,51**	0,49	**13,4**	**0,65**	0,47	**7,8**
IoU+Topo	**0,48**	0,50	**15,8**	0,62	0,46	**8,3**
clDice+Topo	**0,49**	0,51	**17,4**	0,59	0,50	11,1
IoU+clDice+Topo	**0,50**	0,51	**18,2**	0,57	0,49	11,2

Tabla B.4: Fiabilidad de las detecciones en val $\boldsymbol{B}$. Prec.: aciertos entre predicciones, TP/(TP+FP). Exh.: aciertos entre filamentos de referencia, TP/869. Sin fil.: porcentaje de predicciones que no tocan ningún filamento. En negrita, los valores en los que todas las variantes con Topograph mejoran a todas las variantes sin él.

B.3 Incertidumbre de las comparaciones

La Tabla B.5 da la diferencia de PQ de cada ejecución con la baseline (semilla 42) y su intervalo del 95 %, obtenido por *bootstrap* pareado por días (Capítulo 5). Sin post-proceso, solo Topograph con la semilla 42 mejora a la baseline de forma significativa; con la semilla 43 también la mejora (+0,011), pero su intervalo incluye el 0, e IoU es significativamente peor. Con B2, siete de las nueve ejecuciones quedan significativamente por debajo.

Estos intervalos deben leerse con cuidado. La baseline con la semilla 43 es significativamente peor que con la 42 sin post-proceso (−0,024) y casi lo es con B2, a pesar de tratarse de la misma configuración. El *bootstrap* por días mide cuánto depende el PQ de los días que forman val $\boldsymbol{B}$, pero no la variabilidad del propio entrenamiento. Con una sola ejecución por pérdida, una diferencia «significativa» puede deberse a que la ejecución de referencia salió especialmente bien o mal.

	Sin post-proceso		B2 (Optuna)	
Pérdida	ΔPQ	IC 95 %	ΔPQ	IC 95 %
Baseline (s42)	—	—	—	—
Baseline (s43)	−0,024*	[−0,039, −0,009]	−0,016	[−0,035, +0,005]
IoU	−0,026*	[−0,044, −0,010]	−0,022*	[−0,037, −0,007]
clDice	+0,002	[−0,011, +0,016]	−0,019*	[−0,036, −0,002]
IoU+clDice	+0,011	[−0,004, +0,024]	−0,010	[−0,030, +0,011]
Topograph (s42)	+0,016*	[+0,001, +0,032]	−0,020*	[−0,035, −0,001]
Topograph (s43)	+0,011	[−0,008, +0,029]	−0,019*	[−0,035, −0,003]
IoU+Topo	+0,004	[−0,017, +0,025]	−0,028*	[−0,047, −0,008]
clDice+Topo	+0,005	[−0,010, +0,022]	−0,025*	[−0,044, −0,006]
IoU+clDice+Topo	+0,007	[−0,009, +0,022]	−0,037*	[−0,055, −0,019]

Tabla B.5: Diferencia de PQ en val *B* con la baseline (semilla 42) e intervalo del 95 % (*bootstrap* pareado por días, 2.000 remuestreos). *: el intervalo no contiene el 0.

B.4 Post-proceso por persistencia

E2 y B2+P se aplicaron a ejecuciones reentrenadas con la semilla 42, que son las ocho pérdidas con la configuración común (*ref.*) y los mejores intentos del ajuste de hiperparámetros de la baseline, clDice y Topograph (*mejor*). Las ejecuciones de la Tabla B.2 no se conservaron, y por el no determinismo del entrenamiento las cifras de los reentrenamientos difieren algo de las suyas. E2 se aplicó a los once modelos y B2+P también (Tablas B.7 y B.6). Los tipos de error de los cuatro post-procesos se detallan para seis de ellos (Tabla B.8).

E2. Queda por debajo de B2 en PQ en los once modelos, entre 0,03 y 0,06 sin Topograph y entre 0,004 y 0,024 con Topograph. En cinco de los seis modelos de la Tabla B.8, los filamentos sin predicción quedan al nivel de la predicción sin post-proceso (B2 los aumenta en entre 48 y 141) y E2 es, de los tres post-procesos, el que conserva más espina; la excepción es clDice+Topo, para el que el ajuste elige un umbral alto (0,68). El ajuste elige δ entre 0,22 y 0,30 en nueve de los once modelos, y los partidos bajan en los seis respecto a la predicción sin post-proceso, con un coste en fusiones pequeño (los unidos suben como mucho en 7). Los partidos pasan de 132 a 107 en la baseline de referencia y de 88 a 45 en Topograph de referencia. En la baseline, donde τ es casi nulo y el filtro apenas actúa, la reducción se debe a la fusión; con Topograph, el

filtro elimina además trozos poco persistentes. B2 deja aún menos partidos en cinco de los seis modelos, pero lo consigue eliminando componentes pequeñas, entre ellas fragmentos, y con ello también filamentos enteros. Para la baseline, el ajuste elige un τ casi nulo (0,03–0,06), y E2 elimina solo un 10–12 % de las predicciones sin filamento; con Topograph elimina entre un 12 y un 38 %, frente a un 3–12 % en las ejecuciones sin él. Por eso, con la baseline, los errores de presencia de E2 son muy superiores a los de B2 (421–479 frente a 321–327), mientras que con Topograph son del mismo orden (321–342 frente a 320–345), aunque con otra composición: E2 pierde menos filamentos y deja más espurias.

B2+P. El resultado depende de si el modelo se entrenó con Topograph (Tabla B.6). En los cinco modelos con Topograph, B2+P iguala o mejora ligeramente el PQ de B2 (hasta +0,012), y tiene siempre menos partidos y unidos y mayor precisión. El menor número de errores de estructura de todo el trabajo, 32, lo da IoU+clDice+Topo con B2+P. En los seis modelos sin Topograph, en cambio, el PQ queda igual (baseline mejor) o por debajo, y la precisión baja en todos, porque la persistencia rescata también espurias muy seguras. Con la baseline de referencia, por ejemplo, los filamentos sin predicción bajan de 238 a 129, pero las predicciones sin filamento suben de 83 a 233.

El ajuste elige siempre un τ muy alto (0,88–1,00) y un área mínima mayor que la de B2 (59–283 píxeles frente a 21–42). Con τ en el máximo del rango, B2+P se reduce prácticamente a B2, así que en val $\boldsymbol{A}$ debería igualarlo como mínimo. No ocurre en seis de los once modelos, cinco de ellos sin Topograph y el mejor intento de Topograph (por ejemplo, 0,343 frente a 0,359 en la baseline de referencia). Con tres parámetros y 60 intentos, la búsqueda no siempre encuentra el óptimo, y parte de la desventaja de B2+P sin Topograph puede deberse a ello.

B.5 Barbas

De los 869 filamentos de val $\boldsymbol{B}$, el 41,4 % tiene al menos una barba, con una media de 0,70 barbas por filamento. Su esqueleto mide en total un 6 % de la longitud de las espinas, y el grosor mediano de un filamento es de 11,4 píxeles a resolución completa (menos de 3 a 512×512), así que el PQ apenas las tiene en cuenta.

Para separar lo que pierde el modelo de lo que se pierde por la resolución, se reduce cada máscara anotada a 512×512, se vuelve a ampliar y se compara con la original. Se

	PQ		P. + U.		Prec.	
Modelo	B2	B2+P	B2	B2+P	B2	B2+P
Baseline (ref.)	**0,370**	0,347	**59**	68	**0,613**	0,498
Baseline (mejor)	0,368	0,368	49	**36**	**0,632**	0,600
IoU	**0,361**	0,353	**47**	50	**0,634**	0,543
clDice (ref.)	**0,344**	0,339	55	**46**	**0,561**	0,516
clDice (mejor)	**0,361**	0,354	58	**49**	**0,567**	0,525
IoU+clDice	**0,363**	0,347	49	49	**0,596**	0,516
Topograph (ref.)	0,348	**0,360**	45	**37**	0,616	**0,630**
Topograph (mejor)	0,362	0,362	52	**34**	0,605	**0,612**
IoU+Topo	0,349	**0,353**	57	**52**	0,569	**0,575**
clDice+Topo	0,335	**0,341**	58	**35**	0,574	**0,607**
IoU+clDice+Topo	0,338	**0,348**	58	**32**	0,559	**0,611**

Tabla B.6: B2 frente a B2+P en val ***B*** en los once modelos reentrenados. P. + U.: partidos más unidos. Prec.: precisión. En negrita, el mejor de los dos post-procesos en cada medida cuando difieren.

Modelo	Sin post	B2	E2	B2+P	τ (E2)
Baseline (ref.)	0,297	**0,370**	0,310	0,347	0,06
Baseline (mejor)	0,303	**0,368**	0,314	**0,368**	0,03
IoU	0,299	**0,361**	0,313	0,353	0,42
clDice (ref.)	0,307	**0,344**	0,307	0,339	0,48
clDice (mejor)	0,320	**0,361**	0,333	0,354	0,21
IoU+clDice	0,317	**0,363**	0,324	0,347	0,26
Topograph (ref.)	0,316	0,348	0,337	**0,360**	0,50
Topograph (mejor)	0,330	**0,362**	0,339	**0,362**	0,15
IoU+Topo	0,305	0,349	0,325	**0,353**	0,50
clDice+Topo	0,299	0,335	0,332	**0,341**	0,48
IoU+clDice+Topo	0,311	0,338	0,327	**0,348**	0,35

Tabla B.7: PQ en val ***B*** de los modelos reentrenados con cuatro post-procesos: ninguno, B2 (umbral y área), E2 (umbral, persistencia y fusión por collado) y B2+P (umbral, y área o persistencia), los tres últimos ajustados en val ***A***. *ref.*: configuración común; *mejor*: mejor intento del ajuste de hiperparámetros (Sección 6.4.2). τ es la persistencia mínima elegida para E2. En negrita, el mejor post-proceso de cada modelo.

Modelo	Post	Partidos	Unidos	Sin pred.	Sin fil.	Prec.	Exh.	Cob. espina
Baseline (ref.)	sin	132	12	97	424	0,376	0,591	0,772
	B2	47	12	238	83	0,613	0,532	0,699
	E2	107	13	97	382	0,403	0,595	0,772
	B2+P	56	12	129	233	0,498	0,589	0,749
Baseline (mejor)	sin	97	15	143	318	0,410	0,544	0,739
	B2	34	15	255	72	0,632	0,516	0,687
	E2	74	17	142	279	0,438	0,544	0,741
	B2+P	21	15	213	116	0,600	0,539	0,688
Topograph (ref.)	sin	88	14	164	199	0,458	0,533	0,715
	B2	31	14	281	64	0,616	0,480	0,669
	E2	45	20	156	165	0,519	0,541	0,733
	B2+P	23	14	260	73	0,630	0,503	0,666
Topograph (mejor)	sin	75	13	189	158	0,498	0,529	0,707
	B2	39	13	237	89	0,605	0,522	0,686
	E2	60	16	191	139	0,525	0,526	0,703
	B2+P	22	12	235	93	0,612	0,520	0,673
IoU+Topo	sin	88	10	168	233	0,431	0,520	0,702
	B2	43	14	224	102	0,569	0,516	0,693
	E2	51	17	165	177	0,490	0,524	0,717
	B2+P	38	14	227	110	0,575	0,521	0,692
clDice+Topo	sin	54	25	172	172	0,466	0,487	0,727
	B2	36	22	234	86	0,574	0,489	0,701
	E2	33	19	229	107	0,557	0,490	0,686
	B2+P	13	22	254	78	0,607	0,480	0,670

Tabla B.8: Tipos de error en val ***B*** de seis modelos reentrenados con los cuatro post-procesos. Partidos, Unidos, Sin pred. y Sin fil. como en la Tabla B.3; Prec. y Exh. como en la Tabla B.4. «Cob. espina»: fracción de la espina anotada cubierta por la predicción (Sección 6.4.1).

obtiene una cobertura de barbas de 0,997, una precisión de 0,908 y un F_1 de 0,950. La máscara a 512×512 conserva, por tanto, las barbas, y la precisión de los modelos debe compararse con ese techo de 0,91, no con 1, porque el reescalado crea pequeñas ramas que la medida cuenta como inventadas. Queda abierto si la resolución de entrada limita la detección, ya que a esa escala una barba mide entre 1 y 3 píxeles.

Las medidas se calcularon sobre los reentrenamientos con la configuración común (Tabla B.9). La baseline tiene el mejor F_1 con y sin post-proceso. En las cuatro parejas que solo se diferencian en clDice, añadirlo baja el F_1; sin post-proceso, la cobertura sube en tres de ellas pero la precisión baja en las cuatro. Una posible explicación es que el esqueleto de las barbas es solo un 6 % del de las espinas, de modo que clDice optimiza sobre todo la continuidad de la espina. Topograph cubre menos barbas y también menos espina (0,715 frente a 0,772), que es el mismo efecto de predecir menos a cambio de predicciones más fiables. Con B2, la cobertura de la espina baja más que la de las barbas, lo que indica que el filtro de área elimina sobre todo filamentos pequeños enteros. Los post-procesos por persistencia apenas cambian el panorama, ya que E2 deja las medidas casi como sin post-proceso y B2+P casi como B2. La baseline mantiene el mejor F_1 con los cuatro post-procesos, y añadir clDice lo baja en todas las parejas y con todos ellos.

B.6 Ajuste de hiperparámetros

Se ajustaron con Optuna los hiperparámetros de la baseline, Topograph y clDice (Sección 5.5). Cada búsqueda dispuso de 3 horas. La baseline completó 15 intentos y se podaron 27; Topograph, 8 y 19, y clDice, 14 y 18. La Tabla B.10 compara el intento de referencia (la configuración común) con el mejor intento en val A.

Con B2, el mejor intento de la baseline queda igual que la referencia, mientras que Topograph sube 0,014 y clDice 0,017, lo que sugiere que la configuración común se adaptaba mejor a la baseline. En ambas pérdidas el mejor intento usa una tasa de aprendizaje mayor, y en Topograph un peso menor que el fijado a priori ($\alpha \approx 0{,}015$ frente a 0,04). La selección en A infla las cifras de esa mitad (clDice pasa de 0,384 en A a 0,361 en B). Los intentos de referencia son, además, un nuevo entrenamiento de cada modelo, y reproducen el patrón del capítulo, ya que sin post-proceso Topograph supera a la baseline (+0,019) y con B2 queda por debajo. En todas las ejecuciones, la época elegida está entre la 8 y la 20 de las 30 entrenadas; las pérdidas topológicas alcanzan su mejor época algo más tarde que la baseline (12–20 frente a 8–14), pero

Pérdida	Cobertura	Precisión	F_1	Ramas inv.	Cob. espina
Techo a 512×512	0,997	0,908	0,950	0,075	0,999
Sin post-proceso					
Baseline	**0,563**	**0,279**	**0,373**	0,222	**0,772**
IoU	0,536	0,268	0,357	0,226	0,741
clDice	0,546	0,248	0,341	0,212	0,754
IoU+clDice	0,554	0,253	0,347	0,200	0,753
Topograph	0,512	0,232	0,320	0,169	0,715
IoU+Topo	0,496	0,275	0,354	0,168	0,702
clDice+Topo	0,537	0,190	0,281	0,229	0,727
IoU+clDice+Topo	0,529	0,240	0,331	0,185	0,728
B2 (Optuna)					
Baseline	0,528	**0,302**	**0,384**	0,174	0,699
IoU	0,521	0,294	0,376	0,186	0,670
clDice	**0,532**	0,249	0,340	0,196	**0,715**
IoU+clDice	0,516	0,266	0,351	0,174	0,704
Topograph	0,504	0,229	0,315	0,155	0,669
IoU+Topo	0,508	0,275	0,357	0,171	0,693
clDice+Topo	0,497	0,202	0,287	0,217	0,701
IoU+clDice+Topo	0,517	0,252	0,339	0,171	0,706
E2					
Baseline	**0,562**	**0,279**	**0,373**	0,223	**0,772**
IoU	0,543	0,266	0,357	0,227	0,743
clDice	0,551	0,244	0,338	0,200	0,756
IoU+clDice	0,515	0,253	0,339	0,199	0,744
Topograph	0,543	0,239	0,332	0,184	0,733
IoU+Topo	0,524	0,270	0,356	0,189	0,717
clDice+Topo	0,474	0,208	0,289	0,189	0,686
IoU+clDice+Topo	0,501	0,258	0,340	0,166	0,711
B2+P					
Baseline	**0,563**	**0,294**	**0,386**	0,205	**0,749**
IoU	0,529	0,270	0,357	0,193	0,711
clDice	0,532	0,255	0,345	0,196	0,731
IoU+clDice	0,524	0,264	0,351	0,178	0,731
Topograph	0,490	0,211	0,295	0,155	0,666
IoU+Topo	0,507	0,283	0,363	0,162	0,692
clDice+Topo	0,474	0,201	0,282	0,204	0,670
IoU+clDice+Topo	0,512	0,257	0,342	0,163	0,680

Tabla B.9: Medidas de barbas en val B de los reentrenamientos (semilla 42) con los cuatro post-procesos. «Ramas inv.»: ramas inventadas por filamento. «Cob. espina»: fracción de la espina cubierta. El techo es la propia anotación reducida a 512×512 y vuelta a ampliar.

siempre lejos de la última, así que no hay indicios de que falten épocas.

					Sin post		B2	
Modelo	Intento	lr	w_d	Peso	PQ *A*	PQ *B*	PQ *A*	PQ *B*
Baseline	ref.	$3{,}0 \cdot 10^{-4}$	10^{-4}	0,50	0,296	0,297	0,359	**0,370**
	mejor	$4{,}0 \cdot 10^{-4}$	$3 \cdot 10^{-6}$	0,33	0,309	0,303	0,367	0,368
Topograph	ref.	$3{,}0 \cdot 10^{-4}$	10^{-4}	0,040	0,307	0,316	0,350	0,348
	mejor	$4{,}0 \cdot 10^{-4}$	$3 \cdot 10^{-6}$	0,015	0,333	**0,330**	0,368	0,362
clDice	ref.	$3{,}0 \cdot 10^{-4}$	10^{-4}	0,25	0,305	0,307	0,340	0,344
	mejor	$7{,}9 \cdot 10^{-4}$	10^{-6}	0,26	0,341	0,320	0,384	0,361

Tabla B.10: Ajuste de hiperparámetros. «Peso» es el de Dice en la baseline, α en Topograph y el de clDice en clDice; w_d es el *weight decay*. El mejor intento se elige por el PQ en val *A* sin post-proceso; su PQ en *A* está inflado por esa selección.

B.7 Test de la competición

Se enviaron al *leaderboard* público los mejores intentos del ajuste de hiperparámetros. Con B2, la baseline y Topograph obtienen un PQ de 0,27 y clDice de 0,30, entre 0,06 y 0,10 por debajo de su PQ en val ***B***. Con B2+P, la baseline y Topograph obtienen 0,28, y Topograph con E2, 0,26, con una caída respecto a val ***B*** de entre 0,08 y 0,10 en todas las configuraciones.

Se comprobaron dos posibles causas de la caída. La distribución de estaciones es equivalente en entrenamiento y test (entre el 14 y el 19 % de las imágenes en cada una), y la de años es parecida (un 17 % de imágenes de 2018–2022 en el test frente a un 13 % en entrenamiento). Ninguna de las dos explica la diferencia. Que clDice quede por delante tampoco permite sacar conclusiones, ya que se trata de un solo envío por modelo y el *leaderboard* público usa solo la mitad de las imágenes del test.

Bibliografía

[1] Ahmadzadeh, A., Adhyapak, R., Chaurasiya, K., Nagubandi, L. A., Aparna, V., Martens, P. C., Pevtsov, A., Bertello, L., Pevtsov, A., Douglas, N., McDonald, S., Bawa, A., Kang, E., Wu, R., Kempton, D. J., Abdelkarem, A., Copeland, P. M., and Seelamneni, S. H. A dataset of manually annotated filaments from H-alpha observations. *Scientific Data 11* (2024).

[2] Ahmadzadeh, A., Kempton, D. J., Li, Q., and Pevtsov, A. A. Solar filament segmentation challenge 2026. `https://www.kaggle.com/competitions/filament-segmentation-2026`, 2026. Kaggle.

[3] Akiba, T., Sano, S., Yanase, T., Ohta, T., and Koyama, M. Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining* (2019), pp. 2623–2631.

[4] Bernasconi, P. N., Rust, D. M., and Hakim, D. Advanced automated solar filament detection and characterization code: Description, performance, and results. *Solar Physics 228* (2005), 97–117.

[5] Cohen, J. A coefficient of agreement for nominal scales. *Educational and Psychological Measurement 20*, 1 (1960), 37–46.

[6] Cohen-Steiner, D., Edelsbrunner, H., and Harer, J. Stability of persistence diagrams. *Discrete & Computational Geometry 37*, 1 (2007), 103–120.

[7] Crawley-Boevey, W. Decomposition of pointwise finite-dimensional persistence modules. *Journal of Algebra and Its Applications 14*, 5 (2015), 1550066.

[8] Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., and Fei-Fei, L. ImageNet: A large-scale hierarchical image database. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (2009), pp. 248–255.

[9] Dice, L. R. Measures of the amount of ecologic association between species. *Ecology 26*, 3 (1945), 297–302.

[10] Diercke, A., Jarolim, R., Kuckein, C., González Manrique, S. J., Ziener, M., Veronig, A. M., Denker, C., Pötzi, W., Podladchikova, T., and Pevtsov, A. A. A universal method for solar filament detection from Hα observations using semi-supervised deep learning. *Astronomy & Astrophysics 686* (2024), A213.

[11] Edelsbrunner, H., and Harer, J. L. *Computational Topology: An Introduction.* American Mathematical Society, Providence, RI, 2010.

[12] Efron, B., and Tibshirani, R. J. *An Introduction to the Bootstrap.* Chapman & Hall, 1993.

[13] Harvey, J. W., Hill, F., Hubbard, R. P., Kennedy, J. R., Leibacher, J. W., Pintar, J. A., et al. The global oscillation network group (GONG) project. *Science 272*, 5266 (1996), 1284–1286.

[14] Hatcher, A. *Algebraic Topology.* Cambridge University Press, 2002.

[15] He, K., Zhang, X., Ren, S., and Sun, J. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (2016), pp. 770–778.

[16] Hu, X., Li, F., Samaras, D., and Chen, C. Topology-preserving deep image segmentation. In *Advances in Neural Information Processing Systems* (2019), vol. 32.

[17] Iakubovskii, P. Segmentation models PyTorch. `https://github.com/qubvel/segmentation_models.pytorch`, 2019.

[18] Kaczynski, T., Mischaikow, K., and Mrozek, M. *Computational Homology*, vol. 157 of *Applied Mathematical Sciences.* Springer, 2004.

[19] Kirillov, A., He, K., Girshick, R., Rother, C., and Dollár, P. Panoptic segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (2019), pp. 9404–9413.

[20] Loshchilov, I., and Hutter, F. Decoupled weight decay regularization. In *International Conference on Learning Representations (ICLR)* (2019).

[21] Lux, L., Berger, A. H., Weers, A., Stucki, N., Rueckert, D., Bauer, U., and Paetzold, J. C. Topograph: An efficient graph-based framework for strictly topology preserving image segmentation. In *International Conference on Learning Representations* (2025).

[22] Parenti, S. Solar prominences: Observations. *Living Reviews in Solar Physics 11*, 1 (2014).

[23] Ronneberger, O., Fischer, P., and Brox, T. U-Net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015* (2015), pp. 234–241.

[24] Shit, S., Paetzold, J. C., Sekuboyina, A., Ezhov, I., Unger, A., Zhylka, A., Pluim, J. P. W., Bauer, U., and Menze, B. H. clDice – a novel topology-preserving loss function for tubular structure segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (2021), pp. 16560–16569.

[25] Soille, P. *Morphological Image Analysis: Principles and Applications*, 2 ed. Springer, Berlin, 2003.

[26] Solomon, V., Martens, P., Liu, J., and Angryk, R. EdgeAttNet: Towards barb-aware filament segmentation. arXiv:2509.02964, 2025.

[27] Stucki, N., Paetzold, J. C., Shit, S., Menze, B., and Bauer, U. Topologically faithful image segmentation via induced matching of persistence barcodes. In *Proceedings of the 40th International Conference on Machine Learning* (2023), vol. 202 of *PMLR*, pp. 32698–32727.

[28] Zhu, G., Lin, G., Wang, D., Liu, S., and Yang, X. Solar filament recognition based on deep learning. *Solar Physics 294* (2019), 117.